



生物化学实验：数据处理

北京大学 刘凤麟

提纲

1. R语言入门
2. 数据整理：使用tidyverse包
3. 可视化：使用ggplot2包
4. 实验

实验


- 兔肝谷胱甘肽转硫酶**GST**酶活力测定（全班）
- 比较不同研磨方法以及不同pH下酶活的差异
 - 计算统计显著性
 - 选择合适的可视化方式

R语言介绍

- 前身是S编程语言（用于**统计学**）
 - 由贝尔实验室开发，作为S语言的一种开源实现
 - 社区活跃度显著增长
- 2000年，新西兰研究者发布了R的一个稳定版本
- 此后，R的基础研发由志愿者（R核心开发人员）负责，基于公众所提交的方案建议进行
 - 外部开发的扩展包不断涌现，正式托管在**CRAN**上，也有许多被非正式地托管在Github这样的代码共享站点上
- 尽管R最初是为统计学而生的，但它仍然可被视为一种**通用语言**（General Purpose Language, GPL）

R语言的特点

- 开源
- 免费
- 跨平台
- 常用



- 完整的程序设计语言
- 完善的数据类型
- 动态类型，解释执行、调用C、C++、Fortran编译的代码
- 交互式数据分析
- 图形功能丰富
- 实现了经典的、现代的统计方法

为什么生物学家要学习R?

- R擅长用丰富的函数和包来**处理表格**，节省了写循环语句的时间，而生物学数据常以表格的形式呈现
- 便于**统计建模**
- **绘图**美观且相对方便
- **社区**：许多生物信息学方法用R实现且提供相应程序包

Distribution



Correlation




Rankings



Part of a whole



Evolution



Maps



R语言的局限性

- 数据必须装载到内存
- 运行速度较慢


R软件的下载和安装

- R
 - <https://mirrors.tuna.tsinghua.edu.cn/CRAN/>
- IDE: RStudio
 - <https://www.rstudio.com/products/rstudio/download/>

The screenshot displays the RStudio IDE interface with four main panels:

- R script:** The editor shows R code for biomass calculation and plotting. A label "R script" is overlaid on the code.
- Environment:** The "Global Environment" pane lists objects: `hil.trees` (716 obs. of 23 variables), `kal.plot` (94 obs. of 18 variables), `kalimantan` (1993 obs. of 44 variables), and `tsi.plots` (59 obs. of 19 variables). A label "R environment" is overlaid on this pane.
- Console:** The console shows the execution of R commands, including `kal.plot <- merge(kal.plot, Dmed.Hmed.plot, by="Plot")` and `write.csv(kal.plot, "kalimantan")`. A label "R console" is overlaid on the console output.
- Graphical output:** A plot titled "Biomass estimation per plot with different models" is shown. The y-axis is labeled "Biomass (Mg/ha)" and ranges from 100 to 500. The plot displays boxplots for different models: "Brown", "Yamakura", "Basuki", "Samalca", "Hashimoto", "Kenzo", "Ford", "Jaya", and "Novita". A label "Graphical output" is overlaid on the plot.

命令与执行



```
R version 3.4.2 (2017-09-28) -- "Short Summer"
Copyright (C) 2017 The R Foundation for Statistical Computing
Platform: x86_64-w64-mingw32/x64 (64-bit)
```

```
R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.
```

```
R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.
```

```
Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.
```


```
> slice_vector <- c(1,2,3,4,5,6,7,8,9,10)
> slice_vector[1:5]
[1] 1 2 3 4 5
>
> |
```

Type
code

1

2

check output



Select both lines of code that
you want to execute

3

observe output

R语言运行样例

- 四则运算

```
5 + (2.3 - 1.125)*3.2/1.1 + 1.23E3  
## [1] 1238.418
```

- 数学函数

```
sqrt(6.25)  
## [1] 2.5  
exp(1)  
## [1] 2.718282  
log10(10000)  
## [1] 4
```

- 向量运算


```
x1 <- 1:10  
x1  
## [1] 1 2 3 4 5 6 7 8 9 10
```

```
x1 + 200  
## [1] 201 202 203 204 205 206 207 208 209 210  
2*x1  
## [1] 2 4 6 8 10 12 14 16 18 20
```


R语言运行样例

- 绘图

```
curve(sin(x), 0, 2*pi)  
abline(h=0)
```



```
barplot(c("男生"=10, "女生"=7),  
        main="男女生人数")
```



程序包的安装使用

- 例子
 - `install.packages("readr")`
 - `library(readr)`
- 注释符号 #

获得帮助



- 特定函数
 - `help("plot")`
 - `?plot`
 - `??plot`
- 包含指定字符串
 - `apropos("fun")`
 - `help.search("fun")`
- Vignettes and Code Demonstrations
 - `browseVignettes()`
 - `vignette("rotated")`
 - `demo(smooth)`
- R Help on the Internet
 - 搜索引擎
 - <https://cran.r-project.org/web/views/>
- Asking for Help
 - `Stack Overflow`

常见数据类型与运算

- 数据类型

- 基本数据类型

- 数值
 - 逻辑型 (TRUE/FALSE)
 - 文本 (字符串)
 - 支持缺失值, 有专门的复数类型
 - 数据结构: **向量**, **矩阵和数据框**, 多维数组, 列表, 对象等
 - R是**弱类型**的, 因此可以按需修改变量类型

- 变量与常量

- 常量: 数值型、字符型、逻辑型等
 - 变量: 保存各种类型的数据
 - 变量名的第一个字符不能取为数字
 - R是大小写敏感的

数据结构：向量 (vectors)

- 一维数组
- 同质 (same mode)
- 创建数组
 - `math <- c(98,96,97,100,88)`
- 可按位置索引，可按多个位置索引并返回向量
 - `math[1]`
 - `math[c(1,2)]`
- 元素可以被命名
 - `names(math) <- c("Moe", "Larry", "Curly", "Tom", "Jack")`
 - `math["Larry"]`
- 可运算
- 试一试

常用函数


表 2.1 与向量有关的常用函数

函数	含义
<code>length(x)</code>	计算向量 x 的长度
<code>min(x)</code>	返回向量 x 中的最小分量
<code>max(x)</code>	返回向量 x 中的最大分量
<code>which.min(x)</code>	返回向量 x 中最小分量的下标
<code>which.max(x)</code>	返回向量 x 的最大分量的下标
<code>range(x)</code>	返回向量 x 的取值范围
<code>sum(x)</code>	计算 x 中所有分量的和
<code>prod(x)</code>	计算 x 中所有分量的乘积
<code>median(x)</code>	计算 x 中所有分量的中位数
<code>mean(x)</code>	计算 x 中所有分量的平均值
<code>var(x)</code>	计算 x 中分量的方差
<code>sd(x)</code>	计算 x 中分量的标准差
<code>mad(x)</code>	返回 x 的中位绝对离差
<code>IQR(x)</code>	计算 x 的四分位数极差
<code>quantile(x)</code>	计算 x 的五数概括值
<code>quantile(x, probs)</code>	计算 x 的概率为 <code>probs</code> 的分位数

数据结构：数据框（data frame）


- 是一种要求等长的列表
- 允许不同数据类型（数值型、字符型、因子等）
- 必须有列名，可以没有行名
- 创建数据框
- 子集
 - head()

```
> # Create a, b, c, d variables
> a <- c(10,20,30,40)
> b <- c('book', 'pen', 'textbook', 'pencil_case')
> c <- c(TRUE,FALSE,TRUE,FALSE)
> d <- c(2.5, 8, 10, 7)
> # Join the variables to create a data frame
> df <- data.frame(a,b,c,d)
> df
  a      b      c      d
1 10   book  TRUE  2.5
2 20    pen FALSE  8.0
3 30 textbook TRUE 10.0
4 40 pencil_case FALSE 7.0
> df$a
[1] 10 20 30 40
> subset(df, subset = d > 5)
  a      b      c      d
3 30 textbook TRUE 10
4 40 pencil_case FALSE 7
```



数据的输入与输出

- `df <- read.csv('filepath', header = TRUE, sep = ",")`
- `write.csv(df, 'filepath')`
- 在Windows中将路径中的反斜杠 (\) 改为斜杠 (/) 或双反斜杠 (\\)
 - `D:/data/result.csv`




Library	Objective	Function	Default Arguments
utils	Read CSV file	<code>read.csv()</code>	<code>file, header = TRUE, sep = ","</code>
readxl	Read EXCEL file	<code>read_excel()</code>	<code>path, range = NULL, col_names = TRUE</code>
haven	Read SAS file	<code>read_sas()</code>	<code>path</code>
haven	Read STATA file	<code>read_stata()</code>	<code>path</code>
haven	Read SPSS file	<code>read_sav()</code>	<code>path</code>

练习：在R中导入整理好的全班酶活数据表格，存为数据框，命名为`enzymeActivityData`，并预览(View)

常用的包

- Importing data
 - data.table
 - readr
 - RMySQL
 - sqldf
 - jsonlite
- Data visualization
 - ggplot2
- Data manipulation
 - dplyr
 - plyr
 - tidyr
 - reshape2
 - stringr
- Machine learning
 - caret

tidyverse 系统简介



- ggplot2 数据可视化
- tibble 数据类型定义
- tidyr 数据清理
- readr 数据读入（应对多种类型的表格数据） read_delim
- purrr 函数化编程
- stringr 字符串处理
- forcats 因子（factor）处理

```
> library(tidyverse)
-- Attaching packages ----- tidyverse 1.3.0 --
✓ ggplot2 3.3.2   ✓ purrr 0.3.4
✓ tibble 3.0.4    ✓ stringr 1.4.0
✓ tidyr 1.1.2     ✓ forcats 0.5.0
✓ readr 1.4.0
-- Conflicts ----- tidyverse_conflicts() --
✖ dplyr::between() masks data.table::between()
✖ dplyr::filter() masks stats::filter()
✖ dplyr::first() masks data.table::first()
✖ dplyr::lag() masks stats::lag()
✖ dplyr::last() masks data.table::last()
✖ purrr::transpose() masks data.table::transpose()
```

整洁数据

- 每行为一个观测
- 每列为一个变量
- 每个单元格为一个取值
- `data(mtcars)`
- `View(mtcars)`

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.0	6	160.0	110	3.90	2.620	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875	17.02	0	1	4	4
Datsun 710	22.8	4	108.0	93	3.85	2.320	18.61	1	1	4	1
Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215	19.44	1	0	3	1
Hornet Sportabout	18.7	8	360.0	175	3.15	3.440	17.02	0	0	3	2
Valiant	18.1	6	225.0	105	2.76	3.460	20.22	1	0	3	1
Duster 360	14.3	8	360.0	245	3.21	3.570	15.84	0	0	3	4
Merc 240D	24.4	4	146.7	62	3.69	3.190	20.00	1	0	4	2
Merc 230	22.8	4	140.8	95	3.92	3.150	22.90	1	0	4	2
Merc 280	19.2	6	167.6	123	3.92	3.440	18.30	1	0	4	4
Merc 280C	17.8	6	167.6	123	3.92	3.440	18.90	1	0	4	4

对表格的多步操作

- 尝试阅读这段代码：

```
car_data <-  
  transform(aggregate(. ~ cyl,  
                        data = subset(mtcars, hp > 100),  
                        FUN = function(x) round(mean(x, 2))),  
            kpl = mpg*0.4251)
```


管道操作 (pipe)

- 减少开发时间
- 增强可读性和可维护性
- `x %>% f` 等价于 `f(x)`
- `x %>% f %>% g` 等价于 `g(f(x))`
- 如 `mtcars %>% head(2) %>% dim()` 等价于 `dim(head(mtcars,2))`
- `%>%` 的快捷键: `Ctrl+Shift+M`
- 如果管道传递的变量在下一层调用中不是第一自变量, 可以用 `.` 代表

对表格的多步操作

- 尝试阅读这段代码：

```
car_data <-  
  transform(aggregate(. ~ cyl,  
                        data = subset(mtcars, hp > 100),  
                        FUN = function(x) round(mean(x, 2))),  
            kpl = mpg*0.4251)
```

- 转换为：

```
car_data <-  
  mtcars %>%  
  subset(hp > 100) %>%  
  aggregate(. ~ cyl, data = ., FUN = . %>% mean %>% round(2)) %>%  
  transform(kpl = mpg *(0.4251)) %>%  
  print
```

tibble 类型

- 继承了data.frame，与data.frame有相同的语法
- 不关心输入类型，可存储任意类型，包括list
- 没有行名设置 row.names
- 不会对输入进行强制转换：stringsAsFactors=TRUE
- 支持任意列名，不会随便更改列名称
- 会自动添加列名
- Do less (i.e. they don't change variable names or types, and don't do partial matching) and complain more (e.g. when a variable does not exist)
- as_tibble()

选择行子集

- 数据框的任何行子集仍为数据框，即使只有一行而且都是数值也是如此。
- 行子集可以用行下标选取
 - `mtcars %>% slice(2:4)`
 - 正的序号表示保留，负的序号表示排除
 - `head()`; `tail()`
- 筛选 `filter()`
 - `mtcars %>% filter(vs==1, qsec > 18)`
 - 多个条件同时满足
 - 条件中取缺失值的观测自动放弃，这一点与直接在数据框的行下标中用逻辑下标有所不同，逻辑下标中有缺失值会在结果中产生缺失值。
 - 自动舍弃行名，如果需要行名只能将其转换成数据框的一列
- 筛选重复 `distinct()`
 - `mtcars %>% distinct(vs,am,gear)`
 - 对数据框指定若干变量筛选出不同值，每组不同值仅保留一行

选择列子集

- `select()`
 - `mtcars %>% select(mpg, cyl)`
 - 指定变量名
 - 用冒号表示列范围
 - 用数字序号表示列范围
 - 参数中的负号表示扣除

表格操作

- 排序: `arrange()`
 - `mtcars %>% arrange(mpg, desc(wt))`
- 计算新变量: `mutate()`
 - `mtcars %>% mutate(newcol=mpg/wt)`
 - 生成新的数据框
 - 计算公式中可以包含对数据框中变量的统计函数结果
 - 新变量可以与老变量名相同, 这样就在输出中修改了老变量
 - `mtcars <- mtcars %>% mutate(newcol=mpg/wt)`

数据汇总

- `summary()` 显示每列的中位数/平均值等
- `str()` 数据类型等
- `dim()` 行列数
- `table()` 分类计数

假设检验

- 用来判断样本与样本、样本与总体的差异是由抽样误差引起还是本质差别造成的统计推断方法
- 基本思想是“小概率事件”原理：为了检验一个假设 H_0 是否正确，首先假定该假设 H_0 正确，如果样本观察值导致了“小概率事件”发生，就应拒绝假设 H_0

- 提出假设：

1. 建立零假设和备择假设；
2. 确定并计算检验统计量；
3. 给定显著性水平 α ；
4. 确定检验规则，进行统计决策。

若 $P > \alpha$ ，结论为按 α 所取水准不显著，不拒绝 H_0 ，即认为差别很可能是由于抽样误差造成的；如果 $P \leq \alpha$ ，则拒绝 H_0 ，接受 H_1 ，则认为此差别不大可能仅由抽样误差所致，很可能是实验因素不同造成的。

t-test

- t-test 可用来检验两个样本的平均值是否相等
- 零假设：样本均值相等
- 假设：
 - 简单随机样本
 - 被检验的样本来自正态分布
 - Shapiro-Wilk Test 检测是否正态
 - 否则：Wilcoxon Signed-Rank test
 - 方差齐性
 - Levene's test
 - 否则：Welch's t-test (R default)
- 例子：

```
t.test(1:10, 7:20)
```

welch Two Sample t-test

```
data: 1:10 and 7:20
t = -5.4349, df = 21.982, p-value = 1.855e-05
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -11.052802 -4.947198
sample estimates:
mean of x mean of y
    5.5      13.5
```



方差分析

- 方差分析(Analysis of Variance, 简称ANOVA), 用于两个及两个以上样本均数差别的显著性检验。
- 零假设: 样本均值都相等
- **假设:**
 - 样本相互独立
 - 被检验的样本来自正态分布
 - 方差齐性
- 例子:

```
summary(aov(y ~ group, data = df))
```

```
          Df Sum Sq Mean Sq F value Pr(>F)
country    141 210176   1490.6    31.48 <2e-16 ***
Residuals  1562   73973     47.4
```


```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

练习: 在变量名为enzymeActivityData的数据框中筛选出Method_Group列为0的行, 存为新的数据框并命名为homo, 检验在不同匀浆方法下酶活是否具有显著差异。

3. 绘图

数据可视化有助于我们与其他人共享成果，并且可以从中获取关于数据的内在关系的见解



ggplot包介绍

- 图形的语法
 - 将一个作图任务分解为若干个子任务
- 优点
 - 体系化
 - 质量高
 - 易于组合多种类型图形
- 例子

`ggplot(data, aes(x, y)) + geom_X()`
数据 映射 几何图形

样式

- 可修改颜色、符号、线型等图形元素类型
- 可以映射的维度包括x、y、color、fill、shape、size等
 - x、y维度多用于连续变量，但是也可以用于分类变量
 - color、fill可以用于连续变量，用于有序变量，也可以用于无序的分类变量
 - shape只能用于无序的分类变量
- 例子

`ggplot(data, aes(x, y)) + geom_X()`
数据 映射 几何图形

- 散点图: `geom_point()`
 - 每个观测为一个散点
- 折线图: `geom_line()`
- 柱状图: `geom_bar()`
 - 对象计数
- 直方图: `geom_histogram()`
 - `binwidth`
- 箱型图: `geom_boxplot()`
 - `?geom_boxplot`
- 小提琴图: `geom_violin()`
 - 将密度估计曲线旋转90度画出，并左右镜像画两条。它提供了比箱型图更详细的分布信息，如可表现出双峰分布
- 平滑拟合曲线: `geom_smooth()`

ggplot中的各种图形

- 基础图形：
 - `geom_blank()` 不画图，可以按映射的变量设定坐标范围；
 - `geom_point()` 每个观测为一个散点；
 - `geom_hline()`, `geom_vline()`, `geom_abline()` 画线；
 - `geom_path()` 每个观测提供(x, y)坐标，在相邻观测之间连线；
 - `geom_ribbon()` 需要x和ymin, ymax维，在从小到大排序后的相邻观测之间连接阴影区域；
 - `geom_segment()` 需要x, y和xend, yend，为每个观测画一条线段；
 - `geom_rect()` 需要xmin, xmax, ymin, ymax，为每个观测画一个长方形，可有填充色；
 - `geom_polygon()` 需要x, y，将相邻观测连续并连接成一个闭合的多边形，中间填充颜色；
 - `geom_text()` 需要x, y和label，每个观测画一条文字标签。
- 单变量图层：
 - `geom_bar()`, `geom_col()` 作条形图；
 - `geom_histogram()` 对连续变量x作直方图；
 - `geom_density()` 对连续变量x作一元密度估计曲线；
 - `geom_dotplot()` 用原点作直方图；
 - `geom_freqpoly()` 用折线作直方图。

ggplot中的各种图形

- 两变量图形：
 - 两个连续变量x, y:
 - `geom_point()`散点图;
 - `geom_quantile()`拟合分位数回归曲线;
 - `geom_rug()`在坐标轴处画数值对应的短须线;
 - `geom_smooth()`画各种拟合曲线;
 - `geom_text()`在指定的x, y位置画label给出的文字标签;
 - 显示二元分布:
 - `geom_bin2d()`作长方形分块的二维直方图;
 - `geom_density2d()`作二元密度估计等值线图;
 - `geom_hex()`作正六边形分块的二维直方图。
 - 两个变量中有分类变量时:
 - `geom_count()`: 重叠点越多画点越大;
 - `geom_jitter()`: 随机扰动散点位置避免重叠, 数值变量有重叠时也可以用;

ggplot中的各种图形

- 两变量图形：
 - 一个连续变量和一个分类变量：
 - `geom_col()`作条形图，对分类变量的每个值画一个条形，长度与连续变量值成比例；
 - `geom_boxplot()`对每个类做一个盒形图；
 - `geom_violin()`对每个类做一个小提琴图。
 - 一个时间变量和一个连续变量：
 - `geom_area()`作阴影曲线图，曲线下方填充阴影色；
 - `geom_line()`作折线图，在相邻两个时间之间连接线段；
 - `geom_step()`作阶梯函数图，在相邻两个时间之间连接阶梯函数线。
 - 不确定性：
 - `geom_crossbar()`对每个观测输入的x, y, ymin, ymax画中间有线的纵向条形；
 - `geom_errbar()`对每个观测输入的x, ymin, ymax画纵向误差条；
 - `geom_linerange()`对每个观测输入的x, ymin, ymax画一条竖线；
 - `geom_pointrnage()`对每个观测输入的x, y, ymin, ymax画一条中间有点的竖线。
 - 地图：
 - `geom_map()`: 用区域边界坐标数据画边界线地图。

geom_xxx() 参数

ggplot(data, aes(x, y)) + geom_X()

数据 映射 几何图形

- geom_xxx()函数接受许多关于颜色、透明度、符号、线型的设置参数
 - color= 颜色
 - size= 粗细
 - alpha= 透明度
- data(gapminder)
- ggplot(data=gapminder, mapping = aes(x = gdpPercap, y = lifeExp)) + geom_point(alpha=0.5)

主题

- ggplot2包作图可以实现内容与设计的分离
 - 内容指数据、映射、统计、图形类型等方面
 - 设计指背景色、颜色表、字体、坐标轴做法、图例位置等的安排
- theme()函数用来指定设计元素，称为主题(theme)，而且可以单独开发R扩展包来提供适当的主题。ggthemes扩展包是一个这样的包，提供了更多主题选择。
- 对单次绘图，可以直接用+连接theme_gray()等主题函数。

ggplot(data, aes(x, y)) + geom_X() + ...

数据 映射 几何图形


保存图像

- 使用Rmarkdown
 - 图像自动进入编译的结果（如PDF、Word、HTML）
 - 图像大小、输出大小可以用Rmarkdown的设置调整
- 保存最近生成的结果
 - `ggsave(filename="文件名.png")`
- 将制作的图形保存到R变量，用`ggsave(plot=)`参数指定
 - `ggout01 <- p + geom_point()`
 - `ggsave(filename="文件名.pdf", plot=ggout01)`
- 调整图像大小
 - `ggsave(filename="文件名.pdf", height=12, width=8)`

保存图像

```
pdf(file="saving_plot4.pdf")  
hist(Temperature, col="violet")  
dev.off()
```

```
png(file="C:/Datamentor/R-tutorial/saving_plot2.png",  
width=600, height=350)  
hist(Temperature, col="gold")  
dev.off()
```



ggplot绘图总结

- 步骤
 - 准备数据
 - 将数据输入到ggplot()函数中，并指定参与作图的每个变量分别映射到哪些图形特性，比如映射为x坐标、y坐标、颜色、形状等。
 - 调用geom_xxx()函数，指定图形类型，如散点图、曲线图等
 - 继续调用其它函数，控制图例、配色等，用+连接

```
p <- ggplot(data=<输入数据框>,  
  mapping=aes(<维度>=<变量名>,  
    <维度>=<变量名>, <...>))  
p + geom_<图形类型>(<...>) +  
  scale_<映射>_<类型>(<...>) +  
  coord_<类型>(<...>) +  
  labs(<...>)
```

练习：

利用变量名为homo的数据框，用箱线图展现不同研磨方法下酶活的差异。

实验

- 选择合适的数据可视化方式展示：
 - 在不同研磨方法处理下酶活的情况
 - 在不同pH下酶活的情况
- 从统计上看，不同的研磨方法对酶活有影响吗？不同pH呢？

学习更多

- 黄天元 《R语言数据高效处理指南》
- 张杰 《R语言数据可视化之美》
- <https://www.guru99.com/r-tutorial.html>
- <https://www.cedricscherer.com/2019/08/05/a-ggplot2-tutorial-for-beautiful-plotting-in-r/>

备忘单

```
install.packages()
```

```
library()
```

```
# 读入数据
```

```
df <- read.csv()
```

```
# 整理数据框
```

```
df_ph <- df %>% filter()
```

```
df_method <- df %>% filter()
```

```
# 统计
```

```
summary(aov(A ~ B, data))
```

```
t.test()
```

```
# 作图
```

```
ggplot(data, aes(x = , y = )) + geom_boxplot()
```

备忘单

函数	功能
<code>install.packages()</code>	安装程序包
<code>library()</code>	加载程序包到环境
<code>help()</code>	获得帮助
<code>c()</code>	连接
<code>head()</code>	查看前几行
<code>read.csv()</code>	导入表格
<code>View()</code>	预览数据框
<code>filter()</code>	筛选行
<code>t.test()</code>	t检验
<code>aov()</code>	方差分析
<code>summary()</code>	列出方差分析的结果
<code>ggplot()</code>	作图