

2023 年生物信息学期中考试

1. 举例说明生物学大数据的三个特点

数据量大、增长速度快、高度异构

2. 鸟枪法测序，读段平均长为 L 、数量 N 、基因组全长 G ，测序深度 $D=NL/G$ ：

任一核苷酸的测序深度 X 近似服从泊松分布 $\pi(D)$, $P(X = x) = \frac{D^x e^{-D}}{x!}$

①对于某一核苷酸被测到的概率

$$P(X > 0) = 1 - P(X = 0) = 1 - e^{-D}$$

②完整测基因组最小读段数

$$N = -\frac{G}{L} \ln(1 - P(X > 0))$$

3. Semi alignment 公式：

a. 与 global、local alignment 比较，并解释区别对效果造成的影响

b. 三种序列比对算法的应用场景

1) 全局比对:两个序列在整个长度上进行彼此匹配参与比对的两条序列里面的所有字符进行比对。全局比对在全局范围内对两条序列进行比对打分，找出最佳比对，主要被用来寻找关系密切的序列。其可以用来鉴别或证明新序列与已知序列家族的同源性，是进行分子进化分析的重要前提。其代表是 Needleman-Wunsch 算法。

2) 局部比对:不必对两个完整的序列进行比对，而是在每个序列中使用某些局部区域片段进行比对。其产生的需求在于人们发现有的蛋白序列虽然在序列整体上表现出较大的差异性，但是在某些局部区域能独立的发挥相同的功能，序列相当保守。这时候依靠全局比对明显不能得到这些局部相似序列的。其次，在真核生物的基因中，内含子片段表现出了极大变异性，外显子区域却较为保守，这时候全局比对表现出了其局限性，无法找出这些局部相似性序列。其代表是 Smith-Waterman 局部比对算法。

3) 半全局比对:用于将短序列同长序列进行比对，在进行基因匹配的过程中，出了对两个序列进行全局匹配和局部匹配之外，还存在进行半全局匹配的实际需求，即：对某一序列进行全局匹配，对另一序列进行局部匹配，以求解最大匹配度。在 smithwaterman 和 Needleman-Wunsch 算法的基础上，进行如下改进：

(1) 以长序列为行，短序列为列

(2) 在最大值出对应列的最后一行开始回溯

(3) 调整上方和对角方向的优先度，得分相同时，优先采取上方

全局和半全局比对常用 **free-end-gap** 法，即序列末端比对出的 **gap** 和 **gap extend** 罚分较低。

4. 隐马尔可夫模型：

a. 标出对应转移概率

b. 这一模型是否可区分外显子和内含子并解释

5. 你认为最困难、最简单、最有意义、最没有意义的点

6. 写出三个数据库及其功能

dbSNP、SIFT、TCGA、NCBI、KEGG、GO