

前六道选五

1. 给出了一段 fastaq 格式的序列，指出其中高质量（ ≤ 0.001 ）和低质量（ ≥ 0.1 ）的碱基并解释原因

```
@SIM:1:FCX:1:15:6329:1045:GATTACT+GTCTTAAC 1:N:0:ATCCGA
TCGCACTCAACGCCCTGCATATGACAAGACAGAATC
+
<>;##=><9=AAAAAAAAA9#:<#<;<<?????#=>
```

- 第一行，Sequence identifier
- 第二行，Sequence
- 第三行，Quality score identifier line (consisting only of a +)
- 第四行，Quality score，测序质量值

用公式 $Q = -10\log(p_error)$ 计算质量值，p_error（测序错误率）为测序时照相后，图片中数据点的清晰程度，由测序过程中的base calling 算法计算出来，Q值越大，该位置测序正确率越高，测序错误率越低，常用的Q值与对应的错误率如下表，Q20即测序质量值为20，测序正确率为99%，测序错误率为1%；质量值加上质量体系值得ASCII码值，查询ASCII码与ASCII码值对应表如下，得该位置ASCII码。举个例子，第一个碱基T对应的碱基质量ASCII码是<，查询ASCII码表中<对应的ASCII值为60，如果当前测序仪使用的质量体系为Phred33，则T对应的碱基质量值Q为27（60-33），可进一步推算出 $Q = -10\log(p_error)$ 中p_error。

Phred Quality Score	Probability of incorrect base call	Base call accuracy
10	1 in 10	90%
20	1 in 100	99%
30	1 in 1000	99.9%
40	1 in 10,000	99.99%
50	1 in 100,000	99.999%
60	1 in 1,000,000	99.9999%

The decimal set:

0 nul	1 soh	2 stx	3 etx	4 eot	5 enq	6 ack	7 bel
8 bs	9 ht	10 nl	11 vt	12 np	13 cr	14 so	15 si
16 dle	17 dc1	18 dc2	19 dc3	20 dc4	21 nak	22 syn	23 etb
24 can	25 em	26 sub	27 esc	28 fs	29 gs	30 rs	31 us
32 sp	33 !	34 "	35 #	36 \$	37 %	38 &	39 '
40 (	41)	42 *	43 +	44 ,	45 -	46 .	47 /
48 0	49 1	50 2	51 3	52 4	53 5	54 6	55 7
56 8	57 9	58 :	59 ;	60 <	61 =	62 >	63 ?
64 @	65 A	66 B	67 C	68 D	69 E	70 F	71 G
72 H	73 I	74 J	75 K	76 L	77 M	78 N	79 O
80 P	81 Q	82 R	83 S	84 T	85 U	86 V	87 W
88 X	89 Y	90 Z	91 [	92 \	93]	94 ^	95 _
96 `	97 a	98 b	99 c	100 d	101 e	102 f	103 g
104 h	105 i	106 j	107 k	108 l	109 m	110 n	111 o
112 p	113 q	114 r	115 s	116 t	117 u	118 v	119 w
120 x	121 y	122 z	123 {	124	125 }	126 ~	127 del

2. 某科学家在 2020 年初在 NCBI 中进行 blast 测得一蛋白序列 E-value 为 0.1，而 2024 年变为 1，这是为什么？

(1) 数据库的更新或变化：随着数据库中蛋白质序列的增加或更新，BLAST 比对的 E-value 可能会发生变化。2024 年数据库可能比 2020 年更大，包含更多的序列。这样，即使是相似度较高的比对，随着数据库中随机匹配机会的增加，E-value 值也可能增大。因此，

原先的 0.1 可能变成了 1。

- (2) 比对的得分变化：如果目标序列的相似性有所变化（比如因为序列本身发生了突变或者选择了不同的比对参数），得到的比对得分可能会改变。比对得分直接影响 E-value。如果得分降低了，E-value 也可能增大。
- (3) BLAST 参数的调整：BLAST 程序本身可能在 2024 年更新了参数，尤其是与比对计算相关的算法或统计方法。新的版本可能更为严格，导致 E-value 发生变化。比如，最小比对得分的要求、惩罚因子等参数发生了变化，这会直接影响 E-value 的计算。
- (4) 统计模型的更新：BLAST 使用的统计模型（如分布模型）可能随着时间得到改进或变化。新的模型可能会对 E-value 的计算方式产生影响，从而导致相同的比对结果在不同时间点的 E-value 不同。

3. 题中给出了一个计算后的全局比对的矩阵，要求在表中画出回溯路径以及写出比对结果。

4. 根据题中给出的四条序列的比对，补充一张 PSSM 表中空缺的值，odds ratio 以 10 为底，氨基酸的 pseudocount 为 20。

5. Week5-ppt 中的 p27 页，绘制了一个引导树。问在前面操作相同的情况下，第三步分别以表格中的两个 4 为起点，构建出的引导树是否会有不同？

不会不同，简单模拟即可

6. Week4-ppt 中的 p45 页，给出了 semi-global alignment 的算法公式

(1) 能否用这个算法实现 multiple hit？即在长序列上实现短序列的多次比对

不能，因为 semi-global alignment 只允许在序列两端任意添加 gap 而不罚分，因此只能进行一次比对（多次比对相当于在多个同样的短序列之间加入 gap）

(2) 在 RNA-seq 之后需要将其 mapping 到基因组上，但 RNA 存在内含子，要求 RNA 测序读段短序列能与 DNA 长序列的 exon 部分完全比对上，而基因中的内含子则对应 gap。

上述的算法能否实现这个要求。

不能，因为 semi-global alignment 只保证找到短序列在长序列中的最优匹配，而不保证最优匹配一定出现在外显子区

(3) 若 (1) (2) 中有无法实现的部分，请问应该如何更改方法来满足要求。

(1)短序列在长序列上滑动扫描即可 (2)先用 HMM 注释 exon 和 intron，去掉 intron 后再进行比对