

一、方差分析

1. 基本概念：试验指标、因素、水平

2. 单因素方差分析模型

① 模型：第 j 个水平 A_j 下的第 i 个样本 $X_{ij} = \mu_j + \varepsilon_{ij}$ 独立性假设

$\varepsilon_{ij} \sim N(0, \sigma^2)$ ，各 ε_{ij} 间相互独立 正态假设

$j=1, 2, \dots, r, i=1, 2, \dots, n_j$ 方差齐性

假设检验 $H_0: \mu_1 = \mu_2 = \dots = \mu_r (= \mu)$

$H_1: \mu_1, \mu_2, \dots, \mu_r$ 不全相等

总平均 $\mu = \frac{1}{n} \sum_{j=1}^r n_j \mu_j = \bar{X} < \varepsilon_j$

水平 A_j 的效应 $\delta_j = \mu_j - \mu, j=1, 2, \dots, r$

$\Rightarrow \sum_{j=1}^r n_j \delta_j = \sum_{j=1}^r n_j \mu_j - \sum_{j=1}^r n_j \mu = n\mu - n\mu = 0$

$\Rightarrow$ 原模型等价于

$X_{ij} = \mu + \delta_j + \varepsilon_{ij}$

$\varepsilon_{ij} \sim N(0, \sigma^2)$ ，各 ε_{ij} 间相互独立

$j=1, 2, \dots, r, i=1, 2, \dots, n_j$

$\sum_{j=1}^r n_j \delta_j = 0$

假设检验： $H_0: \delta_1 = \delta_2 = \dots = \delta_j = 0$

$H_1: \delta_1, \delta_2, \dots, \delta_j$ 不全为 0

② 平方和分解

总偏差平方和 $S_T = \sum_{j=1}^r \sum_{i=1}^{n_j} (X_{ij} - \bar{X})^2$

效应平方和 $S_A = \sum_{j=1}^r n_j (\bar{X}_{\cdot j} - \bar{X})^2$ 不同水平引起的差异

误差平方和 $S_E = \sum_{j=1}^r \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2$ 同一水平内
随机误差引起的差异

其中 $\bar{X} = \frac{1}{n} \sum_{j=1}^r \sum_{i=1}^{n_j} X_{ij}, \bar{X}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} X_{ij}$

$\Rightarrow a. S_T = S_A + S_E$

b. $E(S_T) = \sum_{j=1}^r n_j \delta_j^2 + (n-1)\sigma^2$

$E(S_A) = \sum_{j=1}^r n_j \delta_j^2 + (r-1)\sigma^2$

$E(S_E) = (n-r)\sigma^2$

证：a. $S_T = \sum_{j=1}^r \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j} + \bar{X}_{\cdot j} - \bar{X})^2$
 $= \sum_{j=1}^r \sum_{i=1}^{n_j} \left[(X_{ij} - \bar{X}_{\cdot j})^2 + 2(X_{ij} - \bar{X}_{\cdot j})(\bar{X}_{\cdot j} - \bar{X}) + (\bar{X}_{\cdot j} - \bar{X})^2 \right]$
 $= S_E + 2 \sum_{j=1}^r (\bar{X}_{\cdot j} - \bar{X}) \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j}) + S_A$
 $= S_E + S_A$

b. $E(S_T) = E\left(\sum_{j=1}^r \sum_{i=1}^{n_j} [X_{ij}^2 - 2\bar{X}_{\cdot j} X_{ij} + \bar{X}_{\cdot j}^2]\right)$

$= \sum_{j=1}^r \sum_{i=1}^{n_j} E(X_{ij}^2) - E(n\bar{X}^2)$

$X_{ij} \sim N(\mu + \delta_j, \sigma^2) \Rightarrow Z = \frac{X_{ij} - \mu - \delta_j}{\sigma}, Z \sim N(0, 1)$

$\Rightarrow E(X_{ij}^2) = E((\sigma Z + \mu + \delta_j)^2) = \sigma^2 + (\mu + \delta_j)^2$

$\bar{X} \sim N(\mu, \frac{\sigma^2}{n}) \Rightarrow E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$

$\Rightarrow S_T = n\sigma^2 + n\mu^2 + 2\mu \sum_{j=1}^r n_j \delta_j + \sum_{j=1}^r n_j \delta_j^2 - \sigma^2 - n\mu^2$
 $= (n-1)\sigma^2 + \sum_{j=1}^r n_j \delta_j^2$

$$\begin{aligned} E(S_E) &= E\left(\sum_{j=1}^r \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2\right) \\ &= \sum_{j=1}^r E\left(\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2\right) \\ &= \sum_{j=1}^r E((n_j - 1)S_j^2) \\ &= \sum_{j=1}^r (n_j - 1)\sigma^2 \\ &= (n-r)\sigma^2 \end{aligned}$$

$$\Rightarrow E(S_A) = E(S_T) - E(S_E) = \sum_{j=1}^r n_j \delta_j^2 + (r-1)\sigma^2$$

□

③ F 检验 检验统计量 $F = \frac{S_A / (r-1)}{S_E / (n-r)}$

当 H_0 成立时

a. $E\left(\frac{S_A}{r-1}\right) = E\left(\frac{S_E}{n-r}\right) = \sigma^2$

b. $\frac{S_E}{\sigma^2} \sim \chi^2(n-r)$

证： $\frac{S_E}{\sigma^2} = \sum_{j=1}^r \sum_{i=1}^{n_j} \left(\frac{X_{ij} - \bar{X}_{\cdot j}}{\sigma}\right)^2 = \sum_{j=1}^r S_{E \cdot j}$

其中 $S_{E \cdot j} \sim \chi^2(n_j - 1)$ ，故 $\frac{S_E}{\sigma^2} \sim \chi^2(n-r)$ □

$\frac{S_T}{\sigma^2} \sim \chi^2(n-1)$ 同理

$\frac{S_A}{\sigma^2} \sim \chi^2(r-1)$

证： $\frac{S_A}{\sigma^2} = \sum_{j=1}^r n_j \left(\frac{\bar{X}_{\cdot j} - \bar{X}}{\sigma}\right)^2, \bar{X}_{\cdot j} \sim N(\mu, \frac{\sigma^2}{n_j}), \bar{X} \sim N(\mu, \frac{\sigma^2}{n})$
 $= \sum_{j=1}^r n_j \left(\frac{\bar{X}_{\cdot j} - \mu + \mu - \bar{X}}{\sigma}\right)^2$
 $= \sum_{j=1}^r \left[n_j \frac{(\bar{X}_{\cdot j} - \mu)^2}{\sigma^2} + n_j \frac{2(\bar{X}_{\cdot j} - \mu)(\mu - \bar{X})}{\sigma^2} \right] +$
 $n \cdot \frac{(\mu - \bar{X})^2}{\sigma^2}$
 $= \sum_{j=1}^r \left(\frac{\sqrt{n_j}(\bar{X}_{\cdot j} - \mu)}{\sigma} \right)^2 - n \frac{(\mu - \bar{X})^2}{\sigma^2}$
 $\sim \chi^2(r) \quad \sim \chi^2(1)$

Cochran 定理

设 $X_1, X_2, \dots, X_n$ 为 n 个独立标准正态随机变量，则 $Q = \sum_{i=1}^n X_i^2 \sim \chi^2(n)$ 。设 $Q = Q_1 + Q_2 + \dots + Q_k$ ，其中 Q_i 为某些随机变量 $\{Y_j\}$ 的平方和，且这些随机变量 Y_j 为 $\{X_i\}$ 的线性组合。设 Q_i 的自由度为 f_i ，则 Q_i 相互独立且满足 $Q_i \sim \chi^2(f_i)$ 的充要条件为 $\sum_{i=1}^k f_i = n$ 。

$df(S_A) = r-1$ ，由 Cochran 定理：

$\frac{S_A}{\sigma^2}$ 与 $n \frac{(\mu - \bar{X})^2}{\sigma^2}$ 相互独立且 $\frac{S_A}{\sigma^2} \sim \chi^2(r-1)$ 。□

e. S_A 与 S_E 相互独立

证： $S_T = S_A + S_E, df(S_A) + df(S_E) = df(S_T)$

由 Cochran 定理： S_A, S_E 相互独立。□

综上， H_0 成立时， $F \sim F(r-1, n-r)$

方差来源	平方和	自由度	均方	F 比
因素 A	S_A	$r-1$	$MS_A = \frac{S_A}{r-1}$	$\frac{MS_A}{MS_E}$
误差	S_E	$n-r$	$MS_E = \frac{S_E}{n-r}$	
总和	S_T	$n-1$		

二、回归分析

1. 一元线性回归模型

样本 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

↓
数 随机变量

模型: $y_i = \alpha + \beta x_i + \varepsilon_i, i=1, 2, \dots, n$

$\varepsilon_i \sim N(0, \sigma^2)$, 相互独立

α, β, σ^2 未知

$y_i \sim N(\alpha + \beta x_i, \sigma^2) \rightarrow$ 点估计 $\hat{\alpha}, \hat{\beta}$

$\hat{y} = \hat{\alpha} + \hat{\beta}x$ 一元线性回归方程

2. 最小二乘法 本质是极大似然法求参数的点估计

$$\text{偏差 } Q(\alpha, \beta) = \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2$$

$$\Rightarrow \hat{\alpha}, \hat{\beta} = \underset{\alpha, \beta}{\operatorname{argmin}} Q(\alpha, \beta)$$

$$\frac{\partial Q}{\partial \alpha} = -2 \sum_{i=1}^n (y_i - \alpha - \beta x_i) = -2 \left(\sum_{i=1}^n y_i - n\alpha - \beta \sum_{i=1}^n x_i \right)$$

$$\frac{\partial Q}{\partial \beta} = -2 \sum_{i=1}^n x_i (y_i - \alpha - \beta x_i) = -2 \left(\sum_{i=1}^n x_i y_i - n\alpha - \beta \sum_{i=1}^n x_i^2 \right)$$

$$\Rightarrow \begin{cases} n\hat{\alpha} + (\sum x_i) \hat{\beta} = \sum y_i \\ n\hat{\alpha} + (\sum x_i^2) \hat{\beta} = \sum x_i y_i \end{cases}$$

$$\text{令 } \bar{y} = \frac{1}{n} \sum y_i$$

$$S_{xx} = \sum (x_i - \bar{x})^2, S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}), S_{yy} = \sum (y_i - \bar{y})^2$$

$$\Rightarrow \begin{cases} \hat{\alpha} + \bar{x} \hat{\beta} = \bar{y} \\ \hat{\alpha} + \frac{\sum x_i^2}{n} \hat{\beta} = \frac{\sum x_i y_i}{n} \end{cases}$$

$$\Rightarrow \left(\frac{\sum x_i^2}{n} - \bar{x} \right) \hat{\beta} = \frac{\sum x_i y_i}{n} - \bar{y}$$

$$\Rightarrow \hat{\beta} = \frac{S_{xy}}{S_{xx}}$$

$$\Rightarrow \hat{\alpha} = \bar{y} - \bar{x} \hat{\beta} \quad \text{回归线过点 } (\bar{x}, \bar{y})$$

下面将 $\hat{\alpha}, \hat{\beta}$ 视作随机变量 $\alpha \sim N(\alpha, (\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}) \sigma^2), \beta \sim N(\beta, \frac{\sigma^2}{S_{xx}})$

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{S_{xx}}, \quad \begin{matrix} T_i \sim N(\alpha + \beta x_i, \sigma^2) \\ \bar{T} \sim N(\alpha + \beta \bar{x}, \frac{\sigma^2}{n}) \end{matrix}$$

$$\Rightarrow E(\hat{\beta}) = \frac{\sum (x_i - \bar{x}) \beta (x_i - \bar{x})}{S_{xx}} = \beta$$

$$E(\hat{\alpha}) = E(\bar{T}) - \bar{x} \hat{\beta} = \alpha$$

$$D(\hat{\beta}) = \frac{1}{S_{xx}} D(\sum (x_i - \bar{x})(T_i - \bar{T}))$$

$$= \frac{1}{S_{xx}} D(\sum (x_i - \bar{x}) T_i - \frac{\sum (x_i - \bar{x}) \bar{T}}{n})$$

$$= \frac{1}{S_{xx}} \cdot \sum (x_i - \bar{x})^2 D(T_i) = \frac{\sigma^2}{S_{xx}}$$

$$D(\hat{\alpha}) = D(\bar{T} - \bar{x} \hat{\beta}) = D(\frac{1}{n} \sum T_i - \bar{x} \frac{\sum (x_i - \bar{x})(T_i - \bar{T})}{S_{xx}})$$

$$= D(\sum [\frac{1}{n} T_i - \frac{\bar{x}(x_i - \bar{x})(T_i - \bar{T})}{S_{xx}}])$$

$$= D(\sum [\frac{1}{n} T_i - \frac{\bar{x}(x_i - \bar{x}) \bar{T}}{S_{xx}}])$$

$$= D(\sum (\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{S_{xx}}) T_i)$$

$$= \sum (\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{S_{xx}})^2 \sigma^2 = (\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}) \sigma^2$$

3. 残差 用于估计 σ^2

$$e_i = y_i - \hat{y}_i, S_e = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \Rightarrow \frac{S_e}{n-2} = \frac{S_{yy} - \hat{\beta} S_{xy}}{n-2} \text{ 为 } \sigma^2 \text{ 的无偏估计}$$

$$\text{证: 先证 } S_e = S_{yy} - \hat{\beta} S_{xy}$$

$$S_e = \sum_{i=1}^n (y_i - \hat{\alpha} - \hat{\beta} x_i)^2$$

$$= \sum_{i=1}^n (y_i - \bar{y} + \hat{\beta} \bar{x} - \hat{\beta} x_i)^2$$

$$= S_{yy} - 2\hat{\beta} S_{xy} + \hat{\beta}^2 S_{xx}$$

$$= S_{yy} - \hat{\beta} S_{xy}$$

$$E(S_e) = E(S_{TT}) - E(\hat{\beta} S_{xy})$$

$$E(S_{TT}) = E(\sum_{i=1}^n (T_i - \bar{T})^2) = E(\sum_{i=1}^n T_i^2 - n\bar{T}^2)$$

$$= \sum_{i=1}^n E(T_i^2) - nE(\bar{T}^2), \quad \begin{matrix} T_i \sim N(\alpha + \beta x_i, \sigma^2) \\ \bar{T} \sim N(\alpha + \beta \bar{x}, \frac{\sigma^2}{n}) \end{matrix}$$

$$E(T_i^2) = D(T_i) + E^2(T_i) = \sigma^2 + (\alpha + \beta x_i)^2$$

$$E(\bar{T}^2) = D(\bar{T}) + E^2(\bar{T}) = \frac{\sigma^2}{n} + (\alpha + \beta \bar{x})^2$$

$$\Rightarrow E(S_{TT}) = n\sigma^2 + \sum_{i=1}^n (\alpha + \beta x_i)^2 - \sigma^2 - n(\alpha + \beta \bar{x})^2$$

$$= (n-1)\sigma^2 + n\alpha^2 + 2\alpha\beta \sum_{i=1}^n x_i + \beta^2 \sum_{i=1}^n x_i^2 - n\alpha^2 - 2n\alpha\beta \bar{x} - n\beta^2 \bar{x}^2$$

$$E(\hat{\beta} S_{xy}) = E(\hat{\beta} \cdot S_{xx}) = S_{xx} E(\hat{\beta}) = S_{xx} (\frac{\sigma^2}{S_{xx}} + \beta) = \sigma^2 + \beta S_{xx}$$

$$\Rightarrow E(S_e) = (n-2)\sigma^2, \quad \square$$

4. 极大似然估计

- 在误差为正态分布假定下, α, β 的最小二乘估计等价于极大似然估计。

$$L(\alpha, \beta) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2 \right\}$$

对 $L(\alpha, \beta)$ 最大化等价于对 $\sum_{i=1}^n (y_i - \alpha - \beta x_i)^2$ 最小化, 即最小二乘估计。

- 采用极大似然估计给出参数 α, β 的估计与最小二乘法给出的估计完全一致。

- 采用极大似然估计给出误差 σ^2 的估计如下:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

此估计不是 σ^2 的无偏估计。 $\Rightarrow$ 调整

5. 回归方程显著性检验 F 检验

- 采用最小二乘法估计参数 α, β , 并不需要事先知道 Y 与 x 之间一定具有相关关系。因此 Y 是否为 x 的线性函数: 一要根据专业知识和实践来判断, 二要根据实际观察得到的数据用假设检验方法来判断。

- 即要检验假设 $H_0: \beta = 0, H_1: \beta \neq 0$, 若原假设被拒绝, 说明回归效果是显著的, 否则, 若接受原假设, 说明 Y 与 x 不是线性关系, 回归方程无意义。回归效果不显著的原因可能有以下几种:

- (1) 影响 Y 取值的, 除了 x , 还有其他不可忽略的因素;
- (2) Y 与 x 的关系不是线性关系, 而是其他关系;
- (3) Y 与 x 不存在关系。

$$\text{平方和分解: } SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\left. \begin{matrix} SSR \\ SSE \end{matrix} \right\} SST = SSR + SSE$$

- 可以证明, $\frac{SSE}{\sigma^2} = \frac{(n-2)s^2}{\sigma^2} \sim \chi^2(n-2)$
- $SSR = \sum (\hat{y}_i - \bar{y})^2 = \hat{\beta}^2 \sum (x_i - \bar{x})^2 = \hat{\beta}^2 s_{xx}$ 由参数估计的性质可知, 当 $\beta = 0$ 时,

$$\frac{SSR}{\sigma^2} = \frac{\hat{\beta}^2 s_{xx}}{\sigma^2} \sim \chi^2(1)$$

- 因此我们有 $F = \frac{SSR/1}{SSE/(n-2)} = \frac{\hat{\beta}^2 s_{xx}}{S^2} \sim F(1, n-2)$

- 方差分析表为

来源	平方和	自由度	均方	F 比
回归	$SSR = s_{xy}^2 / s_{xx}$	$f_R = 1$	$\frac{SSR}{1}$	$F = \frac{SSR/1}{SSE/(n-2)}$
残差	$SSE = (n-2)s^2$	$f_E = n-2$	$\frac{SSE}{n-2}$	
总的	$SST = s_{yy}$	$f_T = n-1$		