

HW4 实验报告

蒙特卡洛方法估计状态值函数

随机生成episode，并根据结果更新状态值函数即可。

结果如下

-0.22	-0.69	-0.083	-0.046	-0.56					
	-0.43	0	0	0	-1.8	-3.6	-0.76	0.073	
	0.54	0	0	0	0	0	0	1	
	4.6	0	0	0	0	0	0	0	5.3
		1.7	0	0	0	0	0	0	1.7
		0.36	0	0	0	0	0	0	0.44
		-0.062	0	0	0	0	0	0	0.015
		0.049	0.085	0	0	0	0	0	0
0.5				0.29	-1.3	-3	-0.17	0	0
								2.9	3.1
2.8									
-0.22	-0.69	-0.083	-0.046	-0.56					
	-0.43	0.012	-0.12	-0.71	-1.8	-3.6	-0.76	0.073	
	0.54	0.68	0.25	-0.31	-0.9	-1.2	-0.088	1	
	4.6	1.9	0.76	0.12	-0.24	-0.2	0.57	2	5.3
		1.7	0.76	0.25	0.017	0.086	0.53	1.2	1.7
		0.36	0.33	0.13	-0.033	-0.0076	0.26	0.53	0.44
		-0.062	0.079	-0.036	-0.27	-0.34	-0.021	0.22	0.015
		0.049	0.085	-0.083	-0.67	-1.1	-0.22	0.36	0.36
0.5				0.29	-1.3	-3	-0.17	1.1	1.3
								2.9	3.1
2.8									
-0.22	-0.69	-0.083	-0.046	-0.56					
	-0.43	0.008	-0.12	-0.72	-1.8	-3.6	-0.76	0.073	
	0.54	0.68	0.25	-0.31	-0.9	-1.2	-0.096	1	
	4.6	1.9	0.76	0.12	-0.24	-0.2	0.56	2	5.3
		1.7	0.76	0.26	0.019	0.086	0.52	1.2	1.7
		0.36	0.33	0.13	-0.026	-0.014	0.24	0.53	0.44
		-0.062	0.077	-0.041	-0.28	-0.36	-0.036	0.22	0.015
		0.049	0.085	-0.078	-0.66	-1.1	-0.24	0.35	0.35
0.5				0.29	-1.3	-3	-0.17	1.1	1.3
								2.9	3.1
2.8									

与DP结果绝对误差小于0.05。

蒙特卡洛方法控制

使用GPI

- 策略评估：在当前策略下（即on-poloccy），从每个状态-动作对起始完成一个episode（强行保证探索性起步），每个episode后根据return更新值函数。
- 策略提升：每个episode后根据值函数贪心地更新策略。

结果如下

Player Without Ace	Player With Usable Ace.
SSSSSSSSSS	SSSSSSSSSS
SSSSSSSSSS	SSSSSSSSSS
SSSSSSSSSS	SSSSSSSSSS
SSSSSSSSSS	HSSSSSSSHH
SSSSSSSSSS	HHHHHHHHHH
HSSSSSHHHH	HHHHHHHHHH
HSSSSSHHHH	HHHHHHHHHH
HSSSSSHHHH	HHHHHHHHHH
HSSSSSHHHH	HHHHHHHHHH
HHHSSSHHHH	HHHHHHHHHH
HHHHHHHHHH	HHHHHHHHHH

和教材答案一致。