

HW5 实验报告

对比了SARSA (on-policy TD learning) 和Q-learning (off-policy TD learning)。前者使用 t 时刻的 Q 计算 $t+1$ 时刻的动作，后者使用 $t+1$ 时刻的 Q 计算 $t+1$ 时刻的动作。

SARSA

输出结果如下：

```
Sarsa result:  
(0,3)->(1,3)->(2,3)->(3,3)->(3,5)->(4,6)->(5,6)->(6,6)->(7,6)->(8,6)->  
(9,6)->(9,5)->(9,4)->(9,3)->(9,2)->(8,2)->(7,3).  
Episode length: 16
```

小于17步，符合预期。

Q-learning

输出结果如下：

```
Q learning result:  
(0,3)->(1,3)->(2,3)->(3,3)->(4,4)->(5,5)->(6,6)->(7,6)->(8,6)->(9,6)->  
(9,5)->(9,4)->(9,3)->(9,2)->(8,2)->(7,3).  
Episode length: 15
```

与教材结果相同，符合预期。