

基于转录组学分析果蝇大脑衰老的细胞与分子特征

姓名 刘沛雨	学号 2100012289	院系 信息科学技术学院
姓名 李梓宁	学号 2200017781	院系 元培学院
姓名 陈梓航	学号 2200012172	院系 生命科学学院
姓名 吕荪恺	学号 2200010793	院系 数学科学学院
姓名 付格丞	学号 2200012176	院系 生命科学学院

组长 陈梓航

目录

1 课题背景	2
1.1 转录组学视角下的大脑衰老	2
1.2 果蝇衰老过程中全脑细胞转录组的有关研究	2
2 相关科学问题	3
3 文献数据整理	4
4 数据质控流程与方法	5
4.1 Cell Ranger 与数据预处理	5
4.2 Seurat 分析	5
4.3 批次效应校正	5
5 数据分析方法	6
6 计划复现的作图	6
6.1 计划首先复现的作图	6
6.2 之后可能进行复现的作图	7
7 预期研究结果	7
8 预期困难和解决方案	8
8.1 数据处理与分析的复杂性	8
8.2 噪声与批次效应的处理	8
8.3 细胞类型的注释标准难以确定	9
8.4 机器学习模型的可再现性	9
8.5 难以得到准确的结果	9
9 小组分工	9

1 课题背景

1.1 转录组学视角下的大脑衰老

大脑中的复杂功能依赖于多样的神经元和胶质细胞类型，而这些细胞的基因表达状态在衰老过程中会发生动态变化。单细胞 RNA 测序（scRNA-seq）等技术的发展使得研究者能够对大脑细胞的多样性和细胞间的调控状态进行更精细地分析。果蝇作为理想的模式生物，大脑结构相对简单，包含约 10 万个细胞，且其中大部分为神经元，这些神经元的类型可以通过形态、连接方式及功能加以区分。然而，不同类型的神经元在衰老过程中的基因表达和调控网络特性还不完全清楚。因此，对果蝇进行系统性的全脑单细胞测序有望揭示大脑在衰老过程中细胞类型与调控网络的变化，为衰老导致的认知水平下降和脑功能丧失提供更深入的见解。




图 1: 基于单细胞测序识别大脑中的不同细胞类型与研究大脑衰老过程的示意图^[1]

1.2 果蝇衰老过程中全脑细胞转录组的有关研究

本课题基于发表于 2018 年的 A Single-Cell Transcriptome Atlas of the Aging *Drosophila* Brain^[2] 进行。该研究首先通过对不同年龄段（0 天到 50 天）的果蝇大脑进行 scRNA-seq，根据不同标志基因的表达情况识别出了多种细胞类型；之后利用单细胞基因调控网络分析工具 SCENIC，分析了果蝇在衰老过程中大脑转录组以及基因调控网络的特征及其变化情况。该研究的主要发现与成果可以总结为以下几点：

1. 实现了对果蝇全脑的 scRNA-seq，得到了高质量的单细胞测序数据集；在测序结果中识别出了大多数神经元亚型，并且每种神经元亚型中的细胞数量与先前文献中报告的估计值相当。
2. 开发了 SCENIC 平台进行基因调控网络分析，实现了根据关键神经发育因子（如 *Dati*, *Pros*, *Imp*, *Scro* 等）的表达组合（基于调控网络）对神经元进行聚类，进而实现了聚类结果中脑区的识别。

3. 发现随着衰老的发生，大脑中的各种细胞类型基本保持不变，但神经元在脑细胞中的占比略有下降。
4. 发现特定基因（特别是与氧化磷酸化相关的基因）的表达量在衰老中快速（呈指数级）下降，而与核糖体相关的基因则仅表现出轻微下降。
5. 线粒体周转率（mitochondria turnover）和细胞的大小在衰老过程中显著降低。
6. 基于研究发现的细胞水平的衰老特征，通过机器学习方法开发了一套具有较高准确率的果蝇脑细胞年龄预测方法。




图 2: 主要参考文献概述

2 相关科学问题

研究人员利用 scRNA-seq 技术对两个品系（DGRP-551 和 w1118）的果蝇建立了完整的果蝇全脑转录组图谱，基本实现了 $1\times$ “cell-coverage” 的测序量。同时，还对不同年龄段的果蝇全脑进行了 scRNA-seq，得到了各个年龄段的果蝇的大脑转录组数据。

基于这些已经获得的原始数据，我们提出了以下科学问题，并希望能够复现已发表过的结果，对这些问题进行解答：

1. 基于 scRNA-seq 数据可以发现哪些转录因子形成的调控网络？
2. 衰老过程中脑细胞调控网络的变化是否存在细胞类型的特异性？
3. 大脑的衰老是否与脑细胞的某些整体状态或性质存在一定程度上的相关性？如果存在相关性，这些状态或性质如何在细胞层面上表征？
4. 大脑的衰老是否可以通过特定脑区中某些与特定细胞生理活动（如氧化磷酸化或线粒体蛋白表达）相关的基因表达水平来反映？

5. 大脑转录组中包含的特征性信息能否被用来预测脑细胞的年龄？如果能，哪些特征最具有代表性，可达到的预测准确率是多少？

在此基础上，如果时间和条件允许，我们还希望结合已有的分析结果和其他文献尝试探索以下问题：

1. 在大脑衰老的过程中，特定的稀有细胞类型（例如某些神经元亚型或小群体的胶质细胞）是否表现出更强的抗衰老能力或更易受到衰老的影响？这些细胞类型是否具有某些特殊的基因表达或调控机制，帮助它们适应衰老的环境？
2. 果蝇和其他模式生物（如小鼠或人类）的大脑衰老是否涉及相似的基因调控网络？如果是，是否存在保守的调控因子或信号通路在演化上被优先保留下来，以应对衰老过程中的种种不利因素？

3 文献数据整理

原始测序数据保存在 GEO 数据库中 ([GEO:GSE107451](#))，下表展示了部分需要使用的数据的基本信息。

数据文件	测序方法	描述
DGRP-551 & w1118 WholeBrain 57k Dataset	10X	scRNA-seq的原始数据，包含表达矩阵和其他有关信息
DGRP-551 & w1118 WholeBrain 57k Metadata	—	在分析原始数据过程中得到的重要的元数据，如每个细胞在Seurat聚类 and SCENIC聚类的t-SNE图中的坐标
R23E10 Adapted SMART-seq2 R23E10 CEL-seq2 R23E10_SMART-seq2_DGEM.tsv.gz	Adapted Smart-Seq2 CEL-Seq2 Smart-Seq2	CEL-Seq2, SMART-Seq2 和 Adapted SMART-Seq2的测序结果，使用这三种方法对带有GFP标记的细胞进行测序，通过将测序结果和原始数据比较来标注细胞类型
DGRP-551_0d/50d	ATAC-Seq	ATAC-Seq测序结果，通过ATAC-Seq分析特定转录因子结合位点的染色质可及性

该研究还使用了一些先前已发表的文献，主要为果蝇大脑中不同细胞类型或脑区（包括 Lamina/Photoreceptor, T4/T5 Neuron, $\alpha/\beta/\gamma$ Kenyon Cell, Mushroom Body Output Neuron, Clock Neuron, Olfactory Projection Neuron 以及 Optic lobe）的 RNA 测序结果（主要为 bulk RNA-seq，部分为 scRNA-seq）。在研究中主要通过使用这些已知细胞类型或脑区的测序结果来标注该研究中全脑 scRNA-seq 结果中的细胞类型。

4 数据质控流程与方法

4.1 Cell Ranger 与数据预处理

此步对于两种果蝇品系（DGRP-551 和 w1118）分别进行。

1. 使用 fastq-mcf 对所有数据（包括 ATAC-seq, SMART-Seq2 和 CEL-Seq2）去除引物等不相关序列。
2. 进行 cell ranger, 参考索引为 2017 年第三次发布的 FlyBase 数据库（果蝇 r6.16 版本）。
3. 通过 cell ranger 处理得到每个细胞的 UMI 总数和检测到的基因数量，当一个细胞的这两个质控指标的偏离程度超过中位数的 5 个绝对偏差时会被标记为离群值，从而被删去，以排除低表达活性的细胞，确保剩余的细胞在转录活性方面符合预期。

4.2 Seurat 分析

由于文章中没有明确这一步与后面的处理阈值，需要根据经验探索得到数据质控方法，初步拟定的数据质控方法如下：

1. 排除只在极少数细胞中表达的基因

将平均表达不到 0.001 或者没有表达的基因标记为离群点删去。对于使用 CEL-Seq2 方法的细胞，读取数低于 10000 的细胞被删去；而对于使用 SMART-Seq2 方法的细胞，该阈值为 20000。

2. 排除线粒体基因表达比例过高的细胞

通过线粒体基因的 UMI 总和与该细胞总 UMI 的比例得出的每个细胞的线粒体基因表达比例，按照数据情况设定线粒体基因表达比例的阈值为 10-15%（线粒体基因比例超过该阈值的细胞可能是处于应激或死亡状态的细胞，应当从数据中删去）。

3. 筛选高变异基因

使用 Seurat 包的 FindVariableFeatures 函数，根据基因表达的方差筛选高变异基因，选择方差较大（在前 30%）的基因，以提高后续分析的敏感性，从而更有效地捕捉细胞间的表达差异。

4.3 批次效应校正

由于单细胞 RNA 测序数据可能会因为不同的样本来源或实验条件的差异产生批次效应，且这些技术偏差会影响不同细胞间生物学差异的呈现，所以在绘制降维和聚类的图像前应当先消除批次效应的影响。这里可使用 Seurat 包的锚点整合方法，通过 FindIntegrationAnchors 识别不同样本之间的“锚点”细胞，并调用 IntegrateData 函数整合数据，以校正批次效应。基于主成分分析（PCA）的结果，还可以应用 Harmony 校正工具，对各个批次进行校正，从而进一步减少批次效应对后续分析的影响。

5 数据分析方法

以下是初步拟定的数据分析流程与方法，在实际分析过程中可能会结合实际情况做出调整。

1. 基于 SCENIC 推断基因调控网络及与之相关的细胞的状态。

可以通过基因之间的共表达来识别可能的转录因子，并使用 RcisTarget 对每个共表达模块进行顺式调控基序（cis-regulatory motif）分析，以找到对应的靶基因，并进行可视化作图。

2. 基于 SCENIC 的主成分分析结果，寻找合适的调控子，将脑细胞分区。
3. 使用 Gorilla，对不同分区的脑细胞进行 GO 分析，探索与分区相关性最强的细胞生理活动。
4. 使用 AUCell，在原始数据中的各细胞簇中对步骤 2 中发现的基因集合进行分析。
5. 通过比较不同年龄段的数据，分析表达量、细胞类型、各种 GO 标签下的基因集以及步骤 2 中得到的各脑区与大脑年龄变化的相关性。
6. 使用随机森林模型对 Seurat 数据库中的各细胞簇转录组数据与年龄进行回归，比较模型在各细胞簇中预测年龄的准确性。
7. 对步骤 5 中得到的相关性最显著的基因与年龄进行回归预测，得出各基因关于年龄的表达量曲线。

6 计划复现的作图

6.1 计划首先复现的作图

- 图 1A：Seurat 分析结果的 t-SNE 图，使用已发表数据对各细胞簇进行细胞类型的标注。
- 图 3A：SCENIC 分析结果的 t-SNE 图。
- 图 4A：SCENIC 分析结果的主成分分析图。
- 图 4B-D：主要调控子在 SCENIC 的 t-SNE 图中的分布。
- 图 4F：根据不同分区方法得到的脑分区图。
- 图 4G：对不同脑区进行 GO 分析的结果图。
- 图 4J：使用 AUCell 对 Seurat 各细胞簇绘制的 AUC-value 图。
- 图 5：表达量、细胞类型、各种 GO 标签下的基因集以及各脑区与大脑年龄变化的相关性图。
- 图 6D-E：随机森林模型对每个 Seurat 细胞簇的预测得分。
- 图 6F：与年龄相关性最强的几个基因随年龄变化的表达量变化图。

6.2 之后可能进行复现的作图

- 图 1B-D: 展示如何使用不同的 marker 基因进行筛选。将各个细胞簇中细胞的表达模式与已知细胞类型的 marker 基因进行比较, 从而将细胞簇与已知的细胞类型联系起来。
- 图 1F: 展示部分细胞簇标记基因表达量的柱状图。
- 图 1G: 使用非负最小二乘 (NNLS) 回归模型进行 cluster-to-bulk mapping 比对测序结果得到的权重热图。
- 图 2C: 对细胞簇 61 进行子聚类得到的 tSNE 图。
- 图 2D: 将图 2C 中的各个子聚类对应的测序结果与通过其他方法 (CEL-Seq2, SMART-Seq2, adapted SMART-Seq2) 得到的测序结果进行 NNLS 拟合的模型权重热图。
- 图 2E: 对细胞簇 20 进行子聚类得到的 tSNE 图。
- 图 2F: 使用已知的 marker 基因识别图 2E 中各个子聚类的细胞类型, 并使用 NNLS 回归模型拟合得到的模型权重热图。
- 图 2G-J: 识别 OPN 对应的细胞簇中亚细胞类型的 tSNE 图。
- 图 3C: 用不同的调控子组合表达量作为颜色的 t-SNE 图。
- 图 3D: 从 scRNA-seq 数据中把调控子的表达量从小到大排序, 标出可以对应到特定细胞类型的调控子和其可识别的主要基序 (motif)。
- 图 3E: 在 SCENIC 分析结果的 t-SNE 图中标出表达转录因子 Onecut 的神经元; 对果蝇大脑做 ATAC-seq 以进行染色质可及性分析, 验证转录因子 Onecut 在神经元中的广泛表达。

7 预期研究结果

本课题基于对现有数据和其他来源的数据进行分析, 预计可获得以下研究结果:

1. 衰老过程中转录组的整体变化

预计能够观察到大脑衰老过程中 RNA 总含量的减少, 特别是在氧化磷酸化相关基因和线粒体相关基因的表达上, 可能呈现显著的下降趋势。同时, 与核糖体生成和蛋白合成相关的基因表达可能仅表现出轻微的变化。这些转录组层面的变化预计与大脑代谢活性的下降有关。

2. 细胞类型的稳定性与比例变化

大脑细胞类型整体在衰老过程中维持稳定, 但神经元在脑细胞中的比例可能略有下降, 而胶质细胞的比例可能存在相对上升, 这可能反映了神经元在衰老过程中可能更容易受到不利因素的影响。

3. 基因调控网络的动态变化

通过 SCENIC 等方法，预计能够识别衰老过程中不同细胞类型中调控网络的动态变化，特别是某些关键转录因子的活性可能受到衰老的显著影响。此外，不同细胞类型的基因调控网络可能展现出细胞类型特异性的调节模式。

4. 稀有细胞类型的特异性变化

在衰老过程中，某些稀有细胞类型（如特定神经元亚型或小型胶质细胞群体）可能会表现出特异性的基因表达模式变化。

5. 与衰老相关的生物学特性

预期能够通过 GO 分析揭示与衰老存在相关性的指导一些生理活动的基因，例如与线粒体功能、能量代谢和应激反应相关的基因集合。这些功能基因表达量的变化可能与大脑的衰老存在较高的相关性。

6. 年龄预测模型的准确性

通过随机森林回归模型等机器学习方法，预计可以将特定基因的表达模式用于预测单细胞的年龄，并达到较高的预测准确性。

这些预期结果不仅有助于深入理解果蝇大脑衰老的分子机制，还可以为研究其他模式生物和人类大脑的衰老过程提供重要的参考依据。

8 预期困难和解决方案

8.1 数据处理与分析的复杂性

该课题涉及多种生物信息学工具的整合，如 Seurat（用于进行细胞聚类）、SCENIC（用于转录因子活性研究与调控网络分析）等，这些分析对计算资源、数据处理能力和专业知识有较高要求。该研究还使用了 SCoPe 平台提供的可视化和分析功能，复现时也需配置相应的软件环境，确保数据存储和共享的兼容性。

解决方案：使用云计算资源或高性能计算平台以应对大数据的需求；使用 Docker 或 Conda 创建标准化环境，这样在不同平台上操作时更容易保持一致；在合适的条件下，分批处理数据，以减轻单次操作对计算机资源的需求。

8.2 噪声与批次效应的处理

对于 scRNA-seq 数据，单个细胞非常容易产生噪声，并且果蝇不同个体和不同年龄阶段的生物学变异也会对复现实验结果产生影响。除此之外，不同批次之间不可避免地会发生批次效应，批次效应去除不完全或是融合过度都会影响结果。

解决方案：在数据处理中通过质控方法减少数据噪声，例如使用标准化处理和去噪算法来提升数据的稳定性。在数据分析时使用批次效应去除算法（如 Harmony 或 Combat），并针对结果进行多次对比，确保去除批次效应的同时保留关键的生物学特征。

8.3 细胞类型的注释标准难以确定

果蝇大脑细胞的亚型划分可能基于特定的基因表达标志或调控网络特征。复现过程中，需要依据相同的基因标记或注释标准，尤其在聚类时需保证与原始研究相同的聚类层级和分辨率，否则可能导致细胞亚型定义的偏差。

解决方案：使用并整合已知的标记基因和参考文献中的方法对细胞类型进行标注，并确保聚类和分辨率设置与原研究一致。

8.4 机器学习模型的再现性

研究会使用随机森林模型来预测细胞的年龄。复现该模型需确保数据预处理方式、特征提取方法、模型超参数与原研究一致。即使略有不同，也可能影响模型的性能和输出的一致性。特别是在新数据上验证时，因生物样本的随机变异性，模型可能会出现不同的效果，因此需进一步对模型进行微调。

解决方案：严格按照原研究中的数据预处理和模型参数设置来复现模型，并使用原始数据进行测试验证。如果存在偏差，则分析模型的误差来源并调整预处理步骤。

8.5 难以得到准确的结果

由于缺乏充足的验证手段，我们可能会轻易将两种本不相关的现象（他们可能被同一种偶然的因素联系在一起）关联在一起。同时，在分析的过程中也可能会忽略一些重要的细节，导致判断错误。

解决方案：在分析时进行多次验证和交叉比对，避免误将不相关现象进行关联。对于关键结果，尝试使用多种方法验证，以提高分析的准确性和结果的可信度，同时确保结果经过统计检验，避免误判。

9 小组分工

后续的数据分析大致可分为五个部分：

1. 原始数据的 Seurat 分析、聚类与降维。
2. 使用 SCENIC 平台进行调控网络分析，实现基于转录因子组合的大脑分区。
3. 在前两步的基础上进行 GO 分析和 AUCell 分析。
4. 统计特定基因的表达量与年龄相关性，筛选与衰老程度相关的表达特征。
5. 基于机器学习方法，使用随机森林等模型，利用第 4 部分得到的特征实现单细胞年龄的预测。

目前计划每位小组成员负责一部分，吕荪恺负责第一部分（原始数据分析），李梓宁负责第二部分（调控网络分析），陈梓航负责第三部分（GO 分析与 AUCell 分析），付格丞负责第四部分（衰老的分子特征筛选），刘沛雨负责第五部分（机器学习方法预测单细胞年龄）。若条件与时间允许，后续还会开展其他有关方面的探索，由小组成员共同完成。结果汇总和展示也将由小组成员共同完成。

参考文献

- [1] Tzu-Chiao Lu *et al.*, Aging Fly Cell Atlas identifies exhaustive aging features at cellular resolution. *Science* **380**, eadg0934(2023).
- [2] Davie K. *et al.*, A Single-Cell Transcriptome Atlas of the Aging Drosophila Brain. *Cell*. 2018 Aug 9;174(4):982-998.e20.