

# Genomics data analysis 基因组学数据分析


## 多元线性回归、作图颜色

**李程**

北京大学生命科学学院、  
生物信息中心、统计科学中心  
邮件: [cheng\\_li@pku.edu.cn](mailto:cheng_li@pku.edu.cn)

**2023年秋季助教:**

胡影绰 <[hyc0322@stu.pku.edu.cn](mailto:hyc0322@stu.pku.edu.cn)>




课件网页

周二下午3-5点, 北大二教107 | 联系助教加入课程微信群

# 目标问题

1. 探索性数据分析是什么，有哪些作用？
2. 对组学数据做多元回归，得到的残差有什么新用途？
3. 统计作图中使用颜色要注意哪些方面？

# 本节内容




- 举例：多元线性回归
- 回顾：简单线性回归
- **模型**：多元线性回归
- 残差：模型评估和妙用
- **作图**：颜色

# 身高与体重的关系

507 人按性别划分的身高和体重分布图

数据来源: Heinz 2003



<https://www.highcharts.com.cn/demo/highcharts/scatter>

# “变化的一生”研究项目

- 3553名成年美国人参与
- 体重为因变量，身高为唯一的解释变量：

$$\text{体重 (磅)} = -135 + 4.5 \times \text{身高 (英寸)}$$

截距没有特别的含义

回归系数 (身高系数),  
SE=0.13, p-value<0.05  
 $R^2=0.25$

- 对于回归系数，关心三件事
  - 正负：自变量和因变量之间**相关关系的方向**？
  - 大小：自变量对因变量产生多大的影响？  
例子：牙齿白的人平均每年比其他人多挣86美元
  - 含义：结果基于有偏差的数据样本，还是能反映整个群体？  
解决：计算回归系数的**标准误差**，衡量估计值的波动性

# 多种因素和结果的复杂关系

- 其他解释体重的因素：年龄、性别、饮食、运动
- 多元回归计算因变量和每个解释变量的线性关系，同时将其他变量放入“**控制组**”（视为常数）
- 对年龄相同的人，他们的身高和体重是什么关系？

$$\text{体重 (磅)} = -145 + 4.6 \times \text{身高 (英寸)} + 0.1 \times \text{年龄 (岁)}$$

比之前增加了：考虑到年龄后，对于身高对体重的影响有更精确的认识

$$\text{体重 (磅)} = -118 + 4.3 \times \text{身高 (英寸)} + 0.12 \times \text{年龄 (岁)} - 4.8 \times \text{性别}$$

二进制变量（虚拟变量），女性为1，男性为0。性别系数代表：其他因素不变时，性别对女性体重的影响

# 更复杂的影响因素

- 教育、运动量、贫困（粮食补助）、种族（文化和居住）？
- 教育背景和贫困水平相同时，种族和体重的关系？

表 12-1 体重回归方程式表




| 变量                | 系数    | 标准误差 | t统计量  | 假定值   | 95% 置信区间  |
|-------------------|-------|------|-------|-------|-----------|
| 身高                | 4.4   | 0.2  | 21.4  | 0.000 | 4.0~4.8   |
| 年龄                | 0.08  | 0.03 | 2.2   | 0.026 | 0.01~0.2  |
| 性别                | - 5.7 | 1.7  | - 3.4 | 0.001 | -0.9~-2.4 |
| 受教育时间             | - 0.7 | 0.2  | - 3.5 | 0.000 | -1.1~-0.3 |
| 体育活动成绩最靠后的 1/4 的人 | 3.7   | 1.4  | 2.6   | 0.009 | 0.9~6.5   |
| 接受粮食补助            | 5.6   | 2.1  | 2.7   | 0.007 | 1.5~9.7   |
| 非西班牙裔黑人           | 9.7   | 1.3  | 7.2   | 0.000 | 7.0~12.3  |
| 截距                | - 117 |      |       |       |           |

解读思路：  
提示遗传机制或社会因素



# 太平洋岩鱼极度长寿的奥秘

- 对包含88个种的102个岩鱼个体进行了全基因组测序分析
- 通过比较进化树上基因的相对进化速率，研究了进化在趋同基因和路径中对岩鱼寿命的作用，发现了91个与寿命显著相关的基因，包括在细胞生长和增殖、DNA修复和细胞凋亡抑制中发挥作用的候选基因。
- 为了确定独立于其他因素的与岩鱼寿命相关的基因，作者使用两个最能预测寿命的变量，成熟时的体型和最大栖息深度，构建了一个线性模型。进而确定了56个与体型或深度无关的寿命相关的基因，这些基因主要在胰岛素和葡萄糖信号传导中发挥功能。



Science 2021 Origins and evolution of extreme life span in Pacific Ocean rockfishes

[https://mp.weixin.qq.com/s/9eSEIGsBUAbm0m5eHG\\_iTQ](https://mp.weixin.qq.com/s/9eSEIGsBUAbm0m5eHG_iTQ)



# 染色质结构与癌症变异的关系

## Chromatin organization is a major influence on regional mutation rates in human cancer cells

Benjamin Schuster-Böckler<sup>1,2</sup> & Ben Lehner<sup>1,3</sup>

Cancer genome sequencing provides the first direct information on how mutation rates vary across the human genome in somatic cells<sup>1-7</sup>. Testing diverse genetic and epigenetic features, here we show that mutation rates in cancer genomes are strikingly related to chromatin organization. Indeed, at the megabase scale, a single feature—levels of the heterochromatin-associated histone modification H3K9me3—can account for more than 40% of mutation-rate variation, and a combination of features can account for more than 55%. The strong association between mutation rates and chromatin organization is upheld in samples from different tissues and for different mutation types. This suggests that the arrangement of the genome into heterochromatin- and euchromatin-like domains is a dominant influence on regional mutation-rate variation in human somatic cells.


nucleotide polymorphism (SNP) density, and clustered the features using these correlation coefficients as a distance metric.

Surprisingly, we found that at the megabase scale, cancer SNV density is strikingly correlated with many features of somatic cell chromatin organization (Fig. 1). The feature most strongly correlated with cancer SNV density is the repressive histone modification H3K9me3 ( $r = 0.64$ ,  $P < 2.2 \times 10^{-16}$ ). Positive correlations are also observed with other repressive marks including H3K9me2 ( $r = 0.53$ ,  $P < 2.2 \times 10^{-16}$ ), H4K20me3 ( $r = 0.39$ ,  $P < 2.2 \times 10^{-16}$ ). SNV density anti-correlates with levels of H3K4me3 associated with open chromatin ( $r = -0.41$ ,  $P < 2.2 \times 10^{-16}$ ) and H3K9ac ( $r = -0.31$ ,  $P < 2.2 \times 10^{-16}$ ). Moderate anti-correlation is observed with gene density ( $r = -0.28$ ,  $P < 2.2 \times 10^{-16}$ ).


生信思路：关联公共数据中的癌症变异、表观遗传等数据

- 发现紧密染色质与变异频率呈**正相关性**，回归模型的  $R^2$  能解释55%的变异差异
- 主要使用**相关性、热图、线性回归**等分析。
- **亮点**：使用了当时最早发布的癌症全基因组变异数据。 (*Nature* 2012)

# Correlation between mutation rate and genomic features



生信思路：  
使用不同的  
参数证明结  
果的鲁棒性



# 多元回归模型解释的 $R^2$




Figure 4 | Prediction of cancer SNV density variation using integrated models. Cumulative  $R^2$  of linear models, adding the feature on the x axis as a predictor at each step.

## 组学思路：

- 统计关联性提示生物模型
- 对**重要生物问题**和文献熟悉

- 异染色质区域靠近细胞核边缘，容易受到损伤？
- DNA修复酶不容易进入这个区域？
- **自己的思考**：癌症细胞演化时对异染色质（抑制基因表达）的变异选择力弱，导致变异积累？




“... with mutation rates elevated in more heterochromatin-like domains and repressed in more open chromatin. This could reflect differing accessibility to DNA repair complexes, variation in the ability to signal repair or perhaps increased exposure to mutagens at the nuclear periphery.”

# 本节内容

- 举例：多元线性回归
- • 回顾：简单线性回归
- **模型**：多元线性回归
- 残差：模型评估和妙用
- **作图**：颜色

# Advertising数据集

|   | TV    | Radio | Newspaper | Sales (单位: 千) |
|---|-------|-------|-----------|---------------|
| 1 | 230.1 | 37.8  | 69.2      | 22.1          |
| 2 | 44.5  | 39.3  | 45.1      | 10.4          |
| 3 | 17.2  | 45.9  | 69.3      | 9.3           |
| 4 | 151.5 | 41.3  | 58.5      | 18.5          |



开发基于三类广告  
媒体预算的精准预  
测销量的模型?

# 统计模型

$$Y = f(X) + \epsilon$$

$$X = (X_1, X_2, \dots, X_p)$$

- $f$ : 固定但未知, 表达了 $\mathbf{X}$  (预测变量) 提供给 $\mathbf{Y}$  (响应变量) 的**系统、确定** (systematic) 信息
- $\epsilon$ : **随机误差项** (error term), 与 $\mathbf{X}$ 独立、均值为0
  - 测量误差或者没有观测、考虑到的变量
- **统计学习**是关于估计  $f$  的一系列方法, 并对估计的精确性进行**评价**

# 简单线性回归模型

模型:

$$Y \approx \beta_0 + \beta_1 X$$

$$\text{sales} \approx \beta_0 + \beta_1 \times \text{TV}$$

预测:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

估计参数  $\beta$ , 使  
**残差平方和**  
(Residual Sum  
Squares) 最小:


$$e_i = y_i - \hat{y}_i$$

$$\text{RSS} = e_1^2 + e_2^2 + \cdots + e_n^2$$

最小二乘估计:


$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x},$$





# 论文中的“标准误差图”



张老师参加论文  
答辩：看到柱状  
图就会去找误差  
条


图来自于Fujisawa et al. (1)。每个数据点都是通过平均值 + 标准误差来表示（见红圈和红色箭头）。

1. H.Fujisawa, etc. 2017, Life Sciences, 171:39-44.

<https://zhuanlan.zhihu.com/p/27093009>

# 误差线(Error bar)


## 表示数据分布或离散度



# 标准差(SD)与标准误差(SE)

Standard  
Deviation

Standard  
Error



$$s = \sqrt{\frac{\sum (x - \mu)^2}{n-1}} \quad SE = \frac{s}{\sqrt{n}}$$

SE =  $\frac{s}{\sqrt{n}}$  总体标准差 / 样本大小

<https://mp.weixin.qq.com/s/VTKeWGMNZJel7BRM-dfacQ>


[https://blog.csdn.net/anshuai\\_aw1/article/details/82769742](https://blog.csdn.net/anshuai_aw1/article/details/82769742)

# 标准差(SD)与标准误差(SE)

## 标准误差

$$SE = \frac{S}{\sqrt{n}}$$

S 总体标准差  
n 样本大小



样本平均值概率图

|      | 标准差                                                                                                                                           | 均数的标准误                                                                                                                                                                |
|------|-----------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 统计符号 | 总体标准差用 $\sigma$ 表示<br>样本标准差用 $S$ 表示                                                                                                           | 均数的标准误用 $\sigma_{\bar{x}}$ 表示<br>其估计值用 $s_{\bar{x}}$ 表示                                                                                                               |
| 计算公式 | $S = \sqrt{\frac{\sum(x - \bar{x})^2}{n - 1}}$                                                                                                | $s_{\bar{x}} = S / \sqrt{n}$                                                                                                                                          |
| 区别   | <p>统计学意义</p> <p>标准差越小，个体值分布相对越集中，样本均数对数据的代表性越好</p> <p>用途</p> <p>描述个体值的变异程度；与<math>\bar{x}</math>结合，用以描述个体观测值的分布范围，常用于医学参考值的估计。N越大，s越趋于稳定。</p> | <p>标准误越小，样本均数的分布越集中，样本均数与总体均数的差别越小，抽样误差越小，由样本均数估计总体均数的可靠性越大</p> <p>描述均数的抽样误差大小；与<math>\bar{x}</math>结合用以估计总体均数可能出现的范围以及对总体均数做假设检验。N越大，<math>s_{\bar{x}}</math>越小。</p> |
| 联系   | <p>① 都是描述变异程度的指标</p> <p>② <math>s_{\bar{x}} = S / \sqrt{n}</math></p>                                                                         |                                                                                                                                                                       |

# 标准误差：度量参数估计的准确性

(Standard Error, 参数估计值的标准差)

$$SE(\hat{\beta}_0)^2 = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right], \quad SE(\hat{\beta}_1)^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$Y = \beta_0 + \beta_1 X + \epsilon \quad \sigma^2 = \text{Var}(\epsilon)$$

$\sigma$  估计值:  $RSE = \sqrt{RSS/(n-2)}$   
残差标准误, residual standard error

理论vs.直观：当  
每个  $x$  的取值更分散时， $n$  更大时，  
取值更小

模型假设：需要每个  $\epsilon$  独立，有相同的方差（在残差图中是否成立？）

# 对参数进行假设检验

- **零假设** ( $H_0$ ) :  $X$  和  $Y$  之间没有关系

$$\beta_1 = 0, \quad Y = \beta_0 + \varepsilon$$

做t-检验：需要error正态分布的模型假设

- **备选假设** ( $H_a$ ) :  $X$  和  $Y$  之间有一定的关系

$$\beta_1 \neq 0$$

- $\beta_1$  是否是0? 在零假设下, 比较  $\beta_1$  估计值的大小 vs. 准确性 (标准误差)。用  **$t$  统计量** 度量:

$$t = \frac{\hat{\beta}_1 - 0}{\text{SE}(\hat{\beta}_1)}$$

**p-value** 是零假设成立时, 观测到大于等于  $|t|$  的概率




|           |           | Coefficient | Std. error | t-statistic | p-value  |
|-----------|-----------|-------------|------------|-------------|----------|
| $\beta_0$ | Intercept | 7.0325      | 0.4578     | 15.36       | < 0.0001 |
| $\beta_1$ | TV        | 0.0475      | 0.0027     | 17.67       | < 0.0001 |

# 本节内容

- 举例：多元线性回归
- 回顾：简单线性回归
- • **模型**：多元线性回归
- 残差：模型评估和妙用
- **作图**：颜色



# 哪些营销问题还没有回答？



- 广告预算和销量有关吗？
- 这种关系有多强？
- 预测关系是否是线性的？
- 如何精确地估计每种媒体对销量的影响？
- 对未来销量的预测精度如何？
- 哪种媒体能最大程度促进销售？
- 广告媒体之间是否存在协同效应？

单位广告投入获得的  
销售增量？

|           | Coefficient | Std. error | t-statistic | p-value  |
|-----------|-------------|------------|-------------|----------|
| Intercept | 7.0325      | 0.4578     | 15.36       | < 0.0001 |
| TV        | 0.0475      | 0.0027     | 17.67       | < 0.0001 |




# 用每个变量单独预测销量

|           | Coefficient | Std. error | t-statistic | p-value  |
|-----------|-------------|------------|-------------|----------|
| Intercept | 7.0325      | 0.4578     | 15.36       | < 0.0001 |
| TV        | 0.0475      | 0.0027     | 17.67       | < 0.0001 |

TV的回归系数（斜率）最小，因为它的X轴范围大

|           | Coefficient | Std. error | t-statistic | p-value  |
|-----------|-------------|------------|-------------|----------|
| Intercept | 9.312       | 0.563      | 16.54       | < 0.0001 |
| radio     | 0.203       | 0.020      | 9.92        | < 0.0001 |

|           | Coefficient | Std. error | t-statistic | p-value  |
|-----------|-------------|------------|-------------|----------|
| Intercept | 12.351      | 0.621      | 19.88       | < 0.0001 |
| newspaper | 0.055       | 0.017      | 3.30        | 0.00115  |




每个预测方程忽略了其他两种媒体；如何整合这些预测结果？

# 探索性数据分析：pairs() plot

对数据做分析和建模之前，先进行**探索性数据分析**，使用尽量原始数据的数据做图，观察大体模式和值得进一步探索的现象。

- 单变量的**分布**：是否需要log变换？
- 变量之间关系的**散点图**：线性还是非线性关系？
- 识别**离群点**：数据质量问题 vs. 提示有趣的现象

**统计思维**：TV和Radio相关性不高，说明它们是相对独立的变量。同时使用这两个变量做多元回归，是否有更好的预测能力？



```
pairs(Ad[,2:5], pch=16,  
      col=rgb(0,0,1,0.4))
```

# 扩展简单线性回归

包含**多个预测变量**，每个变量有相应的斜率系数：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon$$

$\beta_j$  表示在**所有其他预测变量保持不变**的情况下， $X_j$  增加一个单位对  $Y$  对产生的**平均**效果：


$$\text{sales} = \beta_0 + \beta_1 \times \text{TV} + \beta_2 \times \text{radio} + \beta_3 \times \text{newspaper} + \epsilon$$

# 估计回归系数

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_p x_p$$

用最小二乘法，选择估计值使残差平方和最小：

$$\begin{aligned} \text{RSS} &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \cdots - \hat{\beta}_p x_{ip})^2 \end{aligned}$$



# Advertising数据

|           | Coefficient | Std. error | t-statistic | p-value  | 简单回归<br>系数: |
|-----------|-------------|------------|-------------|----------|-------------|
| Intercept | 2.939       | 0.3119     | 9.42        | < 0.0001 |             |
| TV        | 0.046       | 0.0014     | 32.81       | < 0.0001 | 0.0475      |
| radio     | 0.189       | 0.0086     | 21.89       | < 0.0001 | 0.203       |
| newspaper | -0.001      | 0.0059     | -0.18       | 0.8599   | 0.055       |

解释：在电视和报纸广告预算给定的情况下，在广播广告上多投入1个单位（1000美元），将使销量增加约0.189个单位（189件）

简单回归和多元回归的系数差异：


- 前者忽略其他预测变量，单独预测销量；
- 后者表示在TV和radio广告费保持不变时，报纸广告费用增加1000美元产生的平均效果。

销量和报纸广告  
是否相关？

# 变量之间的相关性

|           | TV     | radio  | newspaper | sales  |
|-----------|--------|--------|-----------|--------|
| TV        | 1.0000 | 0.0548 | 0.0567    | 0.7822 |
| radio     |        | 1.0000 | 0.3541    | 0.5762 |
| newspaper |        |        | 1.0000    | 0.2283 |
| sales     |        |        |           | 1.0000 |

- 报纸广告和销量的关系“被解释”了
- 对广告投放策略的影响？



假设报纸广告对销量没有影响，  
但广播广告能增加销量

Radio

协同投放


Sales

Newspaper

- 单独看报纸广告和销量的关系，是显著的
- 多元回归目的：在考虑到其他变量对销量的影响之后，报纸广告对销量的额外影响



# Polio和冰激凌的关系



## 可能解决方法:

- 同时用温度和冰激凌销量对Polio cases做多元回归
- 可能结果: 温度和polio相关性更强、使冰激凌销量不显著

In the late 1940s, before there was a polio vaccine, public health experts in America noted that polio cases increased in step with the consumption of ice cream and soft drinks. Eliminating such treats was even recommended as part of an anti-polio diet. It turned out that polio outbreaks were most common in the hot months of summer, when people naturally ate more ice cream, showing only an association.



# 检查模型拟合优度： $R^2$

- $R^2$  统计量 ( $\text{Cor}(Y, \hat{Y})^2$ , 参数估计也使之最大化)

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad \text{TSS} = \sum (y_i - \bar{y})^2$$

$$R^2 = \frac{\text{TSS} - \text{RSS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}$$

- TSS (总平方和) : 响应变量 Y 中的总体差异性
- RSS (残差平方和) : 进行Y~X回归后仍然无法解释的差异性 (variation)
- TSS – RSS: 响应变量进行回归后被解释 (消除) 的差异性
- $R^2$ : Y 中的差异能被  $X_j$  线性组合解释的部分所占的比例: 0.8972
  - 0.61 for TV only model
  - 0.89719 for TV + radio model


**Variation in cancer risk among tissues can be explained by the number of stem cell divisions**

Cristian Tomasetti<sup>1\*</sup> and Bert Vogelstein<sup>2\*</sup>

**写作思路:**  
文章标题中写  
Variation ... can  
be explained

Newspaper变量没有改善对训练样本的拟合, 还可能导致模型过拟合

# 检查模型假设：残差图



$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon$$


## 回归模型假设：

- 线性关系；
- 误差项是独立、正态、相同分布  
(计算系数的标准误差、显著性检验时用到这些假设)


**统计思路：**残差图可以揭示模型中不能被统计量（如 $R^2$ ）反映的问题，如非线性关系、误差项方差非恒定

# 用高维散点图帮助理解变量关系

演示 **rgl** 包：三维散点图比二维图能看到哪些额外信息？




为什么TV值大的时候，  
预测的波动性大？



## 观察发现：

- TV变大时，Sales差异性变大，Radio更多影响Sales
- Radio花费多时，Sales随TV增长更快（变量间的协同作用）

# 残差图：高维交互图



**观察：**残差呈现交替正、负  
的规律；

- 某一媒体独展广告费时，  
模型高估了sales
- 广告预算同时用在两种媒  
体时，模型低估了sales  
(媒体间的**协同效应**)

线性平面不能完美拟合数据，  
出现**系统性**预测偏差

# 模型扩展：考虑交互作用

- 协同效应 (synergy) 或交互作用 (interaction)
  - 广播广告的投入增强了电视广告的有效性, TV的斜率随radio的增加而增加。
  - 给定10万美元的预算, 在两种媒体上均分可能比全部投入其中一种媒体能更加促进销售

- 加入第3个预测变量, 交互项 (interaction term)

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \epsilon$$

$$Y = \beta_0 + (\beta_1 + \beta_3 X_2) X_1 + \beta_2 X_2 + \epsilon$$

$$= \beta_0 + \tilde{\beta}_1 X_1 + \beta_2 X_2 + \epsilon$$

- $X_1$  (TV) 对  $Y$  的影响 (斜率) 不再是常数, 而与  $X_2$  (Radio) 的值有关

# TV和Radio的交互作用模型

$$\begin{aligned}\text{sales} &= \beta_0 + \beta_1 \times \text{TV} + \beta_2 \times \text{radio} + \beta_3 \times (\text{radio} \times \text{TV}) + \epsilon \\ &= \beta_0 + (\beta_1 + \beta_3 \times \text{radio}) \times \text{TV} + \beta_2 \times \text{radio} + \epsilon.\end{aligned}$$

$\beta_3$ ：广播广告费增加一个单位时，电视广告效用的增量（反之亦然）

`lm(Sales ~ TV + Radio + TV:Radio)`

|           | Coefficient | Std. error | t-statistic | p-value  |
|-----------|-------------|------------|-------------|----------|
| Intercept | 6.7502      | 0.248      | 27.23       | < 0.0001 |
| TV        | 0.0191      | 0.002      | 12.70       | < 0.0001 |
| radio     | 0.0289      | 0.009      | 3.24        | 0.0014   |
| TV×radio  | 0.0011      | 0.000      | 20.73       | < 0.0001 |

交互项的显著 P 值支持  $H_A: \beta_3 \neq 0$ ，即TV和Radio有交互作用。  
 $R^2$  从89.7%提高到96.8%。

`sales.lm4 <- lm(Sales ~ TV + Radio + TV:Radio)`

检查残差图，模型  
拟合是否满意？



# 用 `lm()` 函数拟合回归模型

- `myfit<-lm(formula,data)`
  - formula指要拟合的模型形式，data是一个数据框，包含了用于拟合模型的数据
  - formula形式如下： $Y \sim X_1 + X_2 + \dots + X_k$ （~左边为响应变量，右边为各个预测变量，预测变量之间用 + 符号分隔）

| R表达式中常用的符号 |                                                                                                                                                           |
|------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| 符号         | 用途                                                                                                                                                        |
| ~          | 分隔符号，左边为响应变量，右边为解释变量，eg：要通过x、z和w预测y，代码为 <code>y~x+z+w</code>                                                                                              |
| +          | 分隔预测变量                                                                                                                                                    |
| :          | 表示预测变量的交互项 eg：要通过x、z及x与z的交互项预测y，代码为 <code>y~x+z+x:z</code>                                                                                                |
| *          | 表示所有可能交互项的简洁方式，代码 <code>y~x*z*w</code> 可展开为 <code>y~x+z+w+x:z+x:w+z:w+x:z:w</code>                                                                        |
| ^          | 表示交互项达到某个次数，代码 <code>y~(x+z+w)^2</code> 可展开为 <code>y~x+z+w+x:z+x:w+z:w</code>                                                                             |
| .          | 表示包含除因变量外的所有变量，eg：若一个数据框包含变量x、y、z和w，代码 <code>y~.</code> 可展开为 <code>y~x+z+w</code>                                                                         |
| -          | 减号，表示从等式中移除某个变量，eg： <code>y~(x+z+w)^2-x:w</code> 可展开为 <code>y~x+z+w+x:z+z:w</code>                                                                        |
| -1         | 删除截距项，eg：表示 <code>y~x-1</code> 拟合y在x上的回归，并强制直线通过原点                                                                                                        |
| ()         | 从算术的角度来解释括号中的元素。Eg： <code>y~x+(z+w)^2</code> 将展开为 <code>y~x+z+w+z:w</code> 。相反，代码 <code>y~x+l((z+w)^2)</code> 将展开为 <code>y~x+h</code> ，h是一个由z和w的平方和创建的新变量 |
| function   | 可以在表达式中用的数学函数，例如 <code>log(y)~x+z+w</code> 表示通过x、z和w来预测 <code>log(y)</code>                                                                               |

<https://blog.csdn.net/lilanfeng1991/article/details/29627405>

# 常见的回归分析错误

- 用回归方程式来分析非线性关系
- 相关关系并不等同于因果关系
- 因果倒置
  - 例子：警察人数多的城市，犯罪率也高
  - 确保解释变量会影响因变量，而不是相反
- 变量遗漏偏差
  - 例子：“常打高尔夫易患心脏病、癌症和关节炎”
  - “打高尔夫球”扮演了两个解释因素：打球、年纪
- 高度相关的解释变量（多元共线性）
- 脱离数据（样本代表的群体）进行推断
- 数据中变量过多（假阳性、高维回归）

**组学思路：**避免用组学变量之间的相关性推出因果结论（可以提示）。需要设计验证实验

# 其它话题

- 多元线性回归
  - 单个媒体对销售量的预测模型忽略了其他媒体
  - 预测变量之间可能有相关性
  - 哪些预测变量更重要?
  - 变量选择
- 线性模型扩展
  - 考虑变量间的交互作用和协同效应
  - 非线性关系
- 模型拟合中的问题
  - 误差项自相关、误差项方差不恒定、离群点、共线性


延伸阅读：《统计学习导论》第3.3节

# 本节内容

- 举例：多元线性回归
- 回顾：简单线性回归
- **模型**：多元线性回归
- • 残差：模型评估和妙用
- **作图**：颜色

# 数据例子：美国消费支出

课后阅读



- 居民收入与工业生产产值、储蓄存在正相关关系，与失业率存在负相关关系

- 关系的强度由**相关系数**来表示。其余的散点图和相关系数表明各个预测变量之间的关系

**R语言通道表示：**

```
uschange %>%
```

```
as.data.frame() %>%
```





```
GGally::ggpairs()
```

# 模型假设

- 假设线性模型是对现实情况的合理近似；也就是说，预测变量和被预测变量之间的关系基本满足这个线性方程。
- 对误差项  $(\varepsilon_1, \dots, \varepsilon_T)$  做出如下假设：
  - 期望为零，否则预测结果会产生系统性偏差
  - 随机误差项彼此不相关；
  - 与预测变量不相关；否则表明模型中应该包含更多变量信息
- 为了方便得到预测区间，需要假设随机误差项服从方差为  $\sigma^2$  的正态分布。

# 预测变量与残差的关系图


每个预测变量与残差之间都没有明显的相关关系，模型较为合理



- 我们期望残差是随机分布的并且不显示任何规律。查看每个预测变量与残差的散点图。如果这些散点图表现出明显的规律，则该关系可能是非线性的，并且需要相应地修改模型。
- 对没有加入到模型中的预测变量绘制其与残差的散点图。如果某个残差图显示出明显的规律，则需要将对应的预测变量加入到模型之中（可能以非线性形式加入）。





# 拟合值与残差的关系图



- 残差与拟合值（预测值）之间也应该没有明显规律。如果观察到明显规律，则残差中可能存在“异方差性”，这意味着残差的方差不是固定的。
- 如果出现异方差性，可能需要对预测变量做对数或者平方根变换

# 异常值点和强影响点

**红线**是包含异常值的数据拟合的回归线，而**黑线**是没有包含异常值数据的回归线。



- 与大多数数据相差甚远的点被称为“**异常值点**”。对模型的参数估计有重大影响的观测点被称为“**强影响点**”。通常情况下，强影响点在 X 方向也是极端的异常值。
- 在进行数据分析之前，先初步熟悉数据。画出 Y 和 X 的散点图是回归分析的起点，并且可以帮助找出异常值。

# 代谢组与BMI的关系


$$\text{BMI} = \frac{\text{体重Kg}}{(\text{身高m})^2}$$

- 分析了2396名志愿者的BMI（体重/身高<sup>2</sup>）数据。通过检测不同的代谢物水平可以成功分辨出**超重的类别**，将不同疾病的发生风险区别开来。
- **代谢组水平和BMI密切相关**。共筛选出49种和BMI有**密切关系**的代谢物，其中大部分是脂质（47%）和氨基酸（29%），也包括一些核苷酸和肽。
- **这些代谢物水平和BMI呈线性关系，大部分随着BMI的增加而升高**
  - 比如葡萄糖、甘露糖这些已经熟知的在胰岛素抵抗中发挥作用的代谢物。
  - 也有一部分随BMI升高而降低，比如反映高密度脂蛋白水平的一些脂质。
  - 和BMI相关性最高的是尿酸盐，**可以解释16%的BMI差异**，这是一种与痛风有关的代谢物。
- 研究人员用这些代谢物做了一个新的模型预测BMI，叫做**mBMI**。mBMI可以准确预测（80-90%）志愿者的真实体重
  - **有一部分mBMI与BMI相去甚远**。不论BMI显示的是正常还是超重，都有可能出现和mBMI不匹配的情况。

用文献知识质控数据


创新思路：提出  
新概念mBMI

# 残差的妙用：代谢BMI



- Correlation between ridge regression model prediction of BMI and actual BMI for all unrelated individuals of European ancestry in the TwinsUK and Health Nucleus dataset.
- The identification of **outliers** is defined below: the **lower box** shows individuals with a much lower predicted BMI (mBMI) than actual BMI
- the **upper box** shows individuals with a much higher mBMI than actual BMI.

# Factors associated with being an mBMI outlier



Participants were split into five groups:


- those whose metabolome **accurately predicted** their BMI (residual after accounting for age, sex, and BMI between 0.5 and 0.5) and whose BMIs were either normal (18.5–25), overweight (25–30), or obese (>30),
- whose **metabolome predicted a substantially higher mBMI than the actual BMI** (residual < 0.5) or a substantially lower mBMI than the actual BMI (residual > 0.5).

■ Normal weight, metabolically healthy  
 ■ Overweight, metabolically overweight  
 ■ Obese, metabolically obese  
 ■ Outlier: Metabolic BMI << BMI  
 ■ Outlier: Metabolic BMI >> BMI



# 残差的妙用：代谢BMI

## Graphical Abstract



## Authors

Elizabeth T. Cirulli, Lining Guo, Christine Leon Swisher, ..., Bernard Thorens, J. Craig Venter, Amalio Telenti

## Correspondence

liz.cirulli@gmail.com (E.T.C.),  
atelenti@scripps.edu (A.T.)

## In Brief


Obesity is a heterogeneous and complex disease that is imprecisely measured by BMI. Cirulli et al. used non-targeted metabolomics and whole-genome sequencing to identify metabolic and genetic signatures of obesity and find that the **metabolome captures clinically relevant phenotypes of obesity and is a better health predictor than genetic risk.**

# 重新定义超重与疾病的关系

- **mBMI  $\leq$  BMI：说明虽然体重较重，但是代谢水平还处于一个健康的状态**，胰岛素抵抗、甘油三酯、高密度脂蛋白、血压、腰臀比、体脂百分比、内脏脂肪百分比和皮下脂肪百分比都和正常体重的健康代谢组相似，疾病的魔爪还触之不及。
- **mBMI  $\geq$  BMI：结果的发现提醒着这些人要有危机意识。**因为在这一组人群中，他们的代谢组所表现出的超重水平是大于体重表型的。
- BMI正常的人也不能掉以轻心，因为既然有“胖得健康”，就一定存在“瘦得不健康”，mBMI扒开了隐藏在BMI表象下的疾病风险相关因素。简单来说，**BMI说你胖了还不算，要代谢组说你胖了，那你就是真“胖”了。**

# 本节内容

- 举例：多元线性回归
- 回顾：简单线性回归
- **模型**：多元线性回归
- 残差：模型评估和妙用




- **作图**：颜色



# A flowchart example

Overview of Cufflinks. <http://www.nature.com/nbt/journal/v28/n5/full/nbt.1621.html>



# Stat Graphs

- 作图颜色

- 对比、强调信息
- 表示数据维度、密度
- 考虑色弱群体
- 多色协调
- 做图要简单

**作图思路：**形式丰富多彩，  
传达的信息简单明了

# Attracting attention by contrast

6  
difficult

●  
easy

2359807754321  
5478904820095  
3554687542558  
558932450●452  
9807754321884  
3554387542568  
2359807754321

The number 6 cannot be picked out from all the other numbers despite a lifetime's experience looking at numbers; searching for it will take about two seconds. By contrast the dot can be seen in a single glance, about ten times faster. The features that pop out are hardwired in the brain, not learned.



difficult



easy




Individual faces also do not pop out from the crowd even though it may be our brother or sister we are looking for. However, the pinkish round shapes of faces in general may be tunable, and so our visual systems can program a series of eye movements to faces. This does not help much in this picture because there are so many faces. The yellow jacket in the image on the right can be found with a single fixation because there is only one yellow object and no other similar colors.


演化而来的大脑寻找动态、差异（危险或食物）

《Visual thinking for design》, Colin Ware


# Attracting attention by contrast




Grey value




Elongation




Curvature




Added surround box




Shape




Added surround color




Filled




Sharpness




Cast shadow




Convex and concave




Sharp vertex





Joined lines



Misalignment




Blinking



《Visual thinking for design》, Colin Ware



# Color adds a dimension



sepal花萼, petal花瓣

— Iris setosa  
— Iris versicolor  
— Iris virginica


# 3D figure vs. heatmap




“Three-dimensional visualizations are effective for spatial data but rarely for other data types.”  
《Nature Methods/Points of View》 Into the third dimension



# R: semi-transparent colors




```
plot(x, y, pch=16)
```



```
plot(x, y, pch=16,  
     col=rgb(0,0,0, 0.05))
```

# R: semi-transparent colors





搭配到其它R做图函数中



# A color test

29 (70 or nothing for color impaired)






<http://colorvisiontesting.com/ishihara.htm>

# Advantage of color-deficiency



《Visual thinking for design》, Colin Ware

# Heatmaps



*Nature  
Communications*

**作者须知:**

Avoid the use of red and green in figures to avoid confusion for colour-blind readers (magenta and turquoise are alternatives)

# Color is relative



The same color  
can look different




Different colors can  
appear to be the same



(\*) are the same color but  
appear to be different.




# Picking a set of colors



Spiraling through hue and saturation while varying lightness can generate a discernible color set distinguishable even in grayscale.




# Color palettes in the RColorBrewer package



《Nature Methods/Points of View》  
Managing deep data in genome browsers

# 法则 3: Keep it simple




Nat Methods 2013 Elements of visual style

“Translate the principles of effective writing to the process of figure design.”



# 《Nature Methods》做图和统计专栏



## Elements of a figure

### Typography – April 2011

Choose typefaces, sizes and spacing to clarify the structure and meaning of the text

### Axes, ticks and grids – March 2013

Make navigational elements distinct and unobtrusive to maintain visual priority of data

### Labels and callouts – April 2013

Figure labels require the same consistency and alignment in their layout as text

### Plotting symbols – June 2013

Choose distinct symbols that overlap without ambiguity and communicate relationships in data

### Arrows – September 2011

Use well-proportioned arrows sparingly and consistently as a guide through complex information

<http://blogs.nature.com/methagora/2013/07/data-visualization-points-of-view.html>  
<https://www.nature.com/collections/qghhqm/pointsofsignificance>

# 课后练习

## 1. 选择阅读下列文献：

- Nature 2012 Chromatin organization is a major influence on regional mutation rates in human cancer cells
- CM 2019 Profound Perturbation of the Metabolome in Obesity Is Associated with Health Risk
- NMet 2020 Three-dimensional facial-image analysis to predict heterogeneity of the human ageing rate and the impact of lifestyle

思考：线性回归分析如何帮助提出生物模型或假说？

如何设计其它生信分析或实验，进一步证明潜在因果关系？

## 2. 数据分析练习

- a) 结合课堂内容，运行`regression2.R`，理解其中R语句的功能和输出结果。
- b) 《统计学习导论》，3.7节（习题），p.85，第8、9题
- c) 阅读“Colors in R”（<http://www.sthda.com/english/wiki/colors-in-r>）、“配色表”（<http://www.peisebiao.cn/>）。

学习使用`RColorBrewer`包，练习使用视觉舒适的颜色搭配。