

果蝇大脑转录组与衰老的基因表达特征

李梓宁 2200017781 元培学院

刘沛雨 2100012289 信息科学技术学院

吕荪恺 2200010793 数学科学学院

陈梓航 2200012172 生命科学学院

付格丞 2200012176 生命科学学院

摘要

本课题采用单细胞转录组技术，复现并分析了果蝇大脑在衰老过程中的基因表达变化特征。利用 Seurat 聚类分析、SCENIC 调控网络分析、氧化磷酸化水平分析及随机森林预测模型，全面解析了衰老过程中果蝇大脑中不同细胞类型及脑区的转录组特征。结果表明，大脑衰老过程中基因表达呈现整体性下降趋势，但细胞类型及其身份得到良好维持。此外，随机森林模型进一步验证了部分基因的表达变化与衰老相关，可作为衰老的分子标志物。研究不仅加深了对果蝇大脑衰老机制的理解，也为未来探索其他模式生物及人类大脑的衰老过程提供了重要参考。

1. 引言

1.1. 课题背景

衰老是一个复杂的生物学过程，涉及多个系统和层次的变化，包含未校正的突变和大分子转变的累积所导致的细胞工作效率和功能改变，涉及 DNA 损伤、氧化应激以及大分子生物合成、降解和周转的减少等生理状态的变化^[1]。在衰老过程中，大脑作为中枢神经系统的核心器官，受到衰老过程的显著影响。随着年龄的增长，大脑中的神经元逐渐丧失功能和数量，同时伴随着一系列组织结构和生理功能的退化。这些变化不仅限于个别细胞的功能衰退，更广泛地影响到神经回路的稳定性和神经网络的动态特征。近年来衰老对大脑的影响已经被多项研究揭示，但由于大脑的高度复杂性和其异质性的特点，如何全面、精准地解析大脑衰老的机制，仍然是神经科学领域亟待解决的重要课题。

随着高通量测序技术，特别是转录组学和单细胞组学的快速发展，研究者们得以从更加微观的层面深入探讨大脑衰老过程中的分子机制。与传统的群体细胞测序相比，单细胞转录组技术能够精准解析组织中不同细胞类型或状态的分布和功能，利用这些技术，

能够系统地分析衰老过程中大脑不同细胞类型的基因表达谱，揭示衰老相关基因的表达模式及其调控机制。

单细胞转录组技术在衰老研究中的应用主要体现在三个方面：挖掘并发现衰老过程中出现的特异性细胞亚型；鉴定出表达水平较低或仅在少数细胞类型中变异的衰老相关基因；解析衰老过程中细胞组成的变化及每种细胞类型的差异表达基因，全面描绘其动态变化规律，为理解衰老的复杂生物学过程提供了重要工具。近年来，许多研究结合了高通量测序技术与单细胞转录组学，重点剖析了果蝇，小鼠等模式生物的衰老过程^{[2][3][4]}。通过对不同物种的比较研究，学者们得以识别出衰老过程中常见的生物学特征，并为大脑衰老的机制研究提供了宝贵的数据支持。

本课题主要聚焦于果蝇的大脑衰老过程，并采用单细胞转录组分析方法，通过复现2018年 *A Single-Cell Transcriptome Atlas of the Aging Drosophila Brain*^[5] 中的研究，系统分析果蝇大脑在衰老过程中的基因表达变化。果蝇具有生命周期短、遗传背景清晰以及实验手段成熟等优势，广泛应用于神经科学和衰老研究中。通过对果蝇大脑转录组的深入分析，研究者可以探讨衰老过程中不同脑区及细胞类型的基因表达特征，为揭示大脑衰老的分子机制提供新的视角和数据支持。此外，本课题通过复现该研究中的分析方法，还能够深入了解单细胞转录组学的研究流程和技术范式，为后续学习与研究奠定方法学基础。

1.2. 科学问题

基于本课题的研究内容和所获得的原始数据可以提出如下三方面的科学问题，并根据分析结果尝试解答。

1.2.1. 果蝇大脑转录组特征差异分析

基于果蝇大脑的转录组学数据，能否通过聚类分析和调控网络分析方法，识别出特定的细胞类型及不同细胞类型间主要的差异表达基因？进一步地，能否通过对这些差异基因的功能比对，推测出不同细胞类型在生理功能上的差异，特别是在衰老过程中，是否存在特异性的衰老模式？

1.2.2. 大脑衰老的整体性或局部性

是否能够揭示大脑衰老过程中转录组的整体变化特征？是否存在某些特定区域或细胞群体在衰老过程中表现出更为显著的基因表达变化，从而提示这些区域可能是衰老的“热点”区域？此外，是否可以在细胞水平上进行分析，揭示衰老过程中的基因表达变

化是否为基因组层面的全局性表达波动，还是某些特定基因在衰老过程中发生了显著的异常变化？

1.2.3. 基于衰老分子标志物的年龄预测

如果能够通过数据分析识别出与衰老程度密切相关的基因，是否可以将这些基因作为表征衰老程度的生物标志物，用于细胞或器官水平上的衰老年龄预测？




图 1 数据来源、样本描述与基本分析流程图

2. 数据描述

2.1. 数据类型

图 1 展示了课题使用的数据来源以及基本分析过程。主要使用的数据来源于原研究提供的对不同年龄段果蝇的全脑单细胞 RNA 测序（scRNA-seq）数据。数据的原始来源为 10x Genomics 平台的测序数据。测序数据经过标准化预处理后形成表达矩阵，其中包含了在不同时间点从果蝇大脑中提取的各个细胞的基因表达情况。为了确保数据的准确性和复现性，本课题在复现过程中还结合了相关文献中的元数据进行比对和验证，有助于深入挖掘衰老过程中基因表达的变化特征，为后续的分析提供可靠的基础。

2.2. 样本描述

本研究选用了两种果蝇品系，分别为 *DGRP-551* 和 *w1118*。研究从果蝇幼虫羽化为成虫后开始计算，在不同的衰老阶段（第 0、1、3、6、9、15、30、50 天）进行解剖获取大脑样品，然后对这些大脑样品进行 scRNA-seq。通过以上方式可有效捕捉衰老过程中大脑中各类细胞基因表达的变化情况。测序得到的原始数据经过一系列清洗和筛选步

骤，最终得到表达矩阵，其中 DGRP-551 包含 9,461 个基因和 29,137 个细胞，w1118 包含 9,349 个基因和 27,765 个细胞。

3. 数据分析

如图 1 所示，复现过程分为四个主要部分：Seurat 聚类分析、SCENIC 调控网络分析、氧化磷酸化水平分析和单细胞年龄预测。首先，通过对预处理后的表达矩阵进行聚类分析，初步划分不同细胞群体并结合已有文献数据对其进行注释。之后通过 SCENIC 工具推断基因调控网络，识别调控子（regulon）并捕捉调控关系。通过结合已知标记基因与发现的调控子，进一步对表达矩阵进行降维分析，划分出具有不同基因表达特性的脑区。完成大脑分区后，对各脑区进行基因本体（GO）富集分析，揭示脑区之间存在显著差异的基因类型，发现氧化磷酸化过程在不同脑区间表现出显著差异。最后，通过对细胞氧化磷酸化水平的动态变化进行分析，发现其与衰老过程密切相关，从而尝试利用表达矩阵进行单细胞年龄预测，同时验证前述分析的可靠性。以下将详细介绍这四个分析步骤的具体方法、作图技巧、分析结果以及在过程中遇到的挑战和解决方案。

3.1. 数据质控

3.1.1. RNA-seq 数据的读取和清理

在 RNA-seq 数据的处理过程中，首先对原始测序数据进行清理，以去除接头序列和引物污染。清理后的序列随后通过 STAR 软件进行比对，比对完成后，对每个基因的表达量进行计数，从而获得基因表达的矩阵数据。最后进行差异表达分析，识别在不同样本之间显著变化的基因，为后续的功能分析提供潜在的生物标志物。

3.1.2. 基因和细胞筛选

为了提高数据的质量，首先删除了那些在任何细胞中均未表达的基因。随后，对每个细胞计算了质量指标，标记为异常的细胞是那些其质量指标偏离中位数超过 5 倍绝对偏差（MAD）的细胞，这些细胞被从数据中剔除。此外，在后续的数据清理过程中，还剔除了那些平均计数低于 0.001 的低丰度基因，进一步减少噪声的影响。经过以上一系列的数据预处理后即可得到表达矩阵，得到的表达矩阵经过初步筛选后可直接用于单细胞年龄预测模型的构建。因此以下描述的数据预处理步骤主要针对 Seurat 聚类分析、氧化磷酸化水平分析和 SCENIC 调控网络分析进行。

3.1.3. Seurat 聚类分析数据预处理




图 2 Seurat 聚类分析数据预处理过程图

在进行聚类前，首先筛选出平均表达量高于 0.001 的基因。之后，进行对数归一化处理（归一化过程的缩放因子为 10,000），以消除样本间因测序深度不同而引起的偏差。在此基础上，使用负二项回归方法对每个细胞的 UMI（唯一分子标识）数量以及线粒体读取百分比等潜在变量进行回归调整。完成数据标准化后，筛选出变异性最高的 937 个基因，作为后续 Seurat 分析的基础。

3.1.4. SCENIC 调控网络和氧化磷酸化水平分析数据预处理




图 3 SCENIC 调控网络和氧化磷酸化水平分析数据预处理过程图

首先对得到的表达矩阵进行标准化。与 3.1.3 的每万（ 10^4 ）标准化方法不同，数据这次采用每百万（ 10^6 ）进行标准化，以提高数据在不同样本之间的可比性。标准化后，再通过对数转换（以先验值 1 为底）进一步处理数据，从而增强数据的可比较性并减少噪声的影响。此步骤不进行负二项回归操作，旨在保留数据中可能存在的潜在信号。

3.2. 数据分析与作图方法

3.2.1. Seurat 聚类分析




图 4 Seurat 聚类分析过程图

a. PCA 降维及 t-SNE 聚类

首先，使用 Seurat 包对预处理后的表达矩阵进行主成分分析（PCA）。在进行 PCA 分析时计算了各主成解释释的方差比例，并选择解释比例超过 1% 的主成分用于后续聚类分析。之后进行 t-SNE 降维并进行可视化，获得细胞的低维表示。为检验聚类结果的稳定性和复现程度，使用元数据中的细胞分类信息对聚类结果进行染色，并观察聚类的效果。此外，为了比较本课题与原文中聚类结果的相似性，定义了聚类纯度的指标，即某一聚类中，出现最多的另一聚类标签的比例。通过计算不同聚类方式下的聚类纯度，判断复现结果与原文结果的一致性。

b. 寻找特征基因及标注特定聚类

利用 Seurat 包寻找每个聚类中的特征基因，特征基因通过计算聚类内外的表达量差异的 p 值确定。对原文中提及的细胞类群及其对应的特征基因，在复现结果中查找对应类群，对这些类群分析其纯度即可确认复现结果与原文结果中的细胞类群间的对应关系。

c. 聚类结果进一步子聚类

提取复现结果中纯度较低的细胞类群，重复 a, b 步骤。根据论文中给出的特征基因将类群进一步划分为子类群，并将新分类标签添加回原始聚类结果。再次计算纯度，观察纯度是否有所增加，从而进一步细化复现结果与原文结果中细胞类群间的对应关系。

3.2.2. SCENIC 调控网络分析




图 5 SCENIC 调控网络分析过程图

a. 基因调控网络推断、模块识别与调控子生成

提取 DGRP-551 品系的果蝇样本数据作为分析对象，移除输入表达矩阵中那些在数据库（dm6 motifs ranking database）中未出现的基因，以确保后续的调控网络计算基于可靠且全面的基因信息。之后计算基因调控网络，在该步骤中移除那些含有少于 20 个基因的转录因子（TF）模块，以确保得到的 TF 模块的生物学意义和稳定性。对于剩余的 TF 模块，进行顺式调控基序分析，确保每个调控子至少包含 10 个目标基因，这一设

置有助于捕捉关键调控关系，同时避免假阳性结果的影响。

b. 调控子活性分析

在 TF 模块分析完成后，基于检测到的调控子，计算每个细胞中调控子的 AUC_{cell} 富集值。具体计算过程如下：使用每个细胞中基因数量的前 1%分位数来作为阈值，确保富集值的计算精准且生物学意义明确。随后，对所有细胞（即 DGRP-551 与 w1118 两个品系的细胞）计算 AUC_{cell} 值，生成完整的富集结果矩阵。后续使用该富集矩阵结合前期的基因表达矩阵进行结果可视化与大脑分区。

c. 降维聚类与可视化

用热图可视化该 AUC_{cell} 富集结果矩阵（图 6），之后将该矩阵转化为 Scanpy 对象，提取 25 个主成分，以便减少数据的维度，同时保留主要信息。在此基础上，进行 t-SNE 降维分析，设置复杂度参数为 50，确保良好的聚类效果和可视化分辨率。在聚类完成后，检查在 t-SNE 可视化图中不同细胞类型、基因以及调控子的分布情况，从而确定大脑分区。




图 6 AUC_{cell} 富集矩阵

3.2.3. 氧化磷酸化水平分析




图 7 氧化磷酸化水平分析过程图

a. GO 富集分析

在 SCENIC 分析得到的大脑分区结果基础上，结合预处理后的表达矩阵可筛选出了不同脑区之间的差异表达基因。为了进一步探究这些差异表达基因的生物学功能，采用基因本体（GO）富集分析工具进行功能注释。

b. 氧化磷酸化水平分析

基于 GO 富集分析的结果，计算所有细胞在氧化磷酸化过程中相关基因的 AUCell 值，并将该值用于分析不同脑区之间氧化磷酸化水平的差异。通过对比不同脑区的 AUCell 值，可以进一步验证前一步 GO 富集分析的结果。

3.2.4. 单细胞年龄预测




图 8 单细胞年龄预测过程图

a. 基因表达量随年龄的变化分析

根据元数据提供的样本年龄数据，将所有细胞按年龄分组，统计每组细胞的 UMI 中位数随年龄的变化曲线。之后通过指数函数拟合曲线，从而揭示基因的总表达量随年龄变化的趋势，建立基因表达与年龄间的数量关系，为后续的年龄预测提供支持。

b. 单细胞年龄预测

使用随机森林模型，以表达矩阵为输入，细胞年龄作为标签进行模型训练。同时，使用 5 折交叉验证评估模型的预测准确率。在此基础上，对 Seurat 聚类分析中得到的每个细胞类群，采用相同的方法进行随机森林模型训练。除了计算每个类群的年龄预测准确率外，还统计了与年龄相关的其他统计数据。例如，拟时序分析得到的扩散成分(DC)，并分析 DC 与年龄之间的相关性；同时，使用前述方法拟合每个细胞类群的基因表达量随年龄的变化趋势并计算相关系数。通过比较不同细胞簇的年龄预测准确率和各项统计数据之间的相关性，综合评估年龄预测的可行性和准确性。

c. 衰老的分子标志物筛选

基于对所有细胞训练的随机森林模型，提取模型中基因的权重信息。根据基因的权重大小对其进行排序并选择前 6 个权重最大的基因，分析其在不同年龄阶段细胞中的表达量变化趋势。通过可视化这些基因在衰老过程中的表达模式变化，可以验证分析的合理性与准确性，进一步筛选出与衰老相关的分子标志物。

4. 结果

4.1. 复现结果展示与分析

4.1.1. Seurat 聚类分析

聚类结果如图 9 所示。由于降维过程存在一定的随机性，复现结果与原文结果之间存在差异，难以实现完全一致的复现结果。同时，聚类产生的细胞类群数量也受到随机种子的影响，但数量误差在 5%以内，因此总体的复现结果是准确的。通过对比复现结果与原文结果，可以观察到以下几点差异：1. 原文中的细胞类群数量略多于复现结果；2. 在图中央的细胞类群，其聚集度较低，而靠近边缘的细胞类群则具有较高的聚集度。通过计算聚类纯度可以解释这一现象：边缘区域的聚类纯度平均达到 80%以上，而中央区域的聚类纯度较低，甚至可能低于 20%。

图 10 展示了对原文中图 1B 的复现结果。在复现过程中，Tdc2 与 SerT 最初被分配到同一个细胞类群中，这一现象启发了进一步的分析。通过对该细胞类群进行子聚类分析，并检查 Tdc2 和 SerT 两种基因的表达情况，发现随着聚类细胞数量的减少，子类群中这两种基因的表达差异变得更为明显。对新得到的子细胞类群进行着色后，与原文结果细胞类群分布相符。计算该子类群的纯度，发现纯度达到了 90%以上（图 11），说明通过进一步的聚类可以提升复现结果的质量。

以上分析结果表明，表达矩阵中数据的整体质量较好。尽管算法的随机性导致复现结果与原文存在一定差异，但在复现结果中仍能发现与原文一致的细胞类型聚集，表明所使用的聚类方法是有效的。

图9 单细胞年龄预测过程图

(B) 原文 Seurat 聚类结果, 共 87 个细胞簇。

图 10 对特定细胞类型的标注

(A) 复现结果




图 11 对 Tdc2 及 SerT 进一步进行子聚类的结果

4.1.2. SCENIC 调控网络分析

下面探究是否可以通过特定的基因调控网络和转录因子组合的表达活性来表征识别出的细胞类型。我们使用和原文中一样的果蝇数据库，使用 SCENIC 平台进行数据分析。对基于 SCENIC 计算得到的基因网络进行聚类（图 12B），结果与单纯根据基因表达得到的结果（图 9）存在明显差异。




图 12 UMAP 与 t-SNE 两种工具降维可视化

(A) 原文 t-SNE 结果。

(B-C) t-SNE 与 UMAP 的复现结果，其中占比较小且没有命名的细胞群作为 unnamed，染成灰色。




图 14 t-SNE 降维结果中不同基因表达的分布情况

(A-C) 原文结果

(D-F) 复现结果

因为表达 *Dati* 和 *pros* 的细胞高度重合，而表达 *Dati* 和 *Imp* 的细胞高度不重合，所以根据这三种调控子以及主调控因子的高度特异性表达，可以将果蝇大脑分为三个区域：*central brain A*，*central brain B* 和 *optic lobe*（图 15）。这一步有助于将细胞分布与特定大脑功能区域关联起来，从而使更深入的生物学分析成为可能。




图 15 大脑分区结果

(A) 原文结果。

(B) 复现结果：根据 *dati*, *pros*, *Imp* 的表达情况，把这些脑细胞分成 *central brain A* (*dati*++), *central brain B* (*Imp*++), *optic lobe*; *Glia* 细胞单独聚类，仍然注释为 *Glia*；其他细胞注释为 *other*。

(C) 在各个脑区中标志基因的表达情况。

4.1.3. 氧化磷酸化水平分析

如前所述，基于调控网络分析可以将大脑划分为具有不同调控子表达模式的三个脑区，那么接下来的问题便是这三个脑区是否在生理水平上存在特定的差异，因此这里对 central brain A 和 B 的细胞进行 GO 富集分析，得到脑区间差异最显著的 15 个 GO 注释，结果如图 16 所示。可以观察到在差异最显著的 15 个 GO 注释中有 7 个均和氧化磷酸化过程相关，说明从生理功能的角度来看，氧化磷酸化水平可能在各个脑区间存在显著差异。




图 16 不同 GO 注释在 central brain A 和 B 间的差异
与氧化磷酸化相关的 GO 注释均由橙色直线标出

结合这些 GO 注释下的基因以及和原文中提供的有关基因计算所有细胞氧化磷酸化过程的 AUC_{cell} 值，并且以 Seurat 聚类得到的细胞簇对细胞分组，对每个细胞簇绘制箱型图，按照其所在的脑区着色，结果如图 17 所示。总体来看，胶质细胞是氧化磷酸化表达水平最低的一个细胞亚群，而 central brain A 细胞的氧化磷酸化水平总体低于 central brain B 与 optic lobe，复现结果和原文结果基本一致。




图 17 不同脑区 AUC_{cell} 值的相对大小关系

(A) 复现结果。

(B) 原文结果。

4.1.4. 单细胞年龄预测

前述分析表明，氧化磷酸化水平在大脑的不同脑区中可能存在较强的异质性，故可尝试在时间维度上进一步分析衰老过程中大脑中基因表达的变化情况，观察其是否与氧化磷酸化水平的动态变化有关。首先统计衰老过程中基因表达量的变化情况，如图 18 所示。

结果与原文基本一致，随着年龄的增长，所有细胞的整体基因表达量呈现出指数下降的趋势。除此之外，还利用文献提供的元数据绘制了不同年龄阶段的 Seurat 聚类结果图（图 19），发现随着年龄的增长，尽管基因表达量逐渐减少，但是大脑整体的细胞类型并未出现明显变化。原文中还通过湿实验进一步验证了表达量出现下降的基因主要为

氧化磷酸化相关的基因（由于时间原因课题中未复现该结果）。




图 18 不同脑区 AUC_{cell} 值的相对大小关系

(A) 复现结果。

(B) 原文结果。




图 19 使用元数据绘制的不同年龄阶段的 Seurat 聚类结果

(A) 年龄为 0、1、3、6 天的细胞的聚类结果

(B) 年龄为 9、15、30、50 天的细胞的聚类结果

由于细胞整体的基因表达量随着衰老呈现出指数下降的趋势，且这些基因主要为氧化磷酸化相关的基因，说明特定基因的表达模式可能与大脑衰老存在密切关系。因此我们使用随机森林模型尝试预测细胞年龄，结果如图 20 所示。由于随机森林算法的随机性较强，并且原文中对该部分的方法描述较少，没有提供随机种子等信息，所以训练得到的模型和原文存在一定差异，导致得到的年龄可预测性（age predictability）结果也存在一些不同。但总体来看，不同 Seurat 细胞簇间年龄可预测性的相对大小关系基本和原

文一致。

图 20 中还展示了统计和计算得到的其他有关数据。使用 `Destiny` 包进行拟时序分析得到的 DC 和年龄的相关性结果和原文大多一致，约 1/3 的细胞类群找到的与年龄相关性最强的 DC 和原文中的不同（用红色标出）。而拟合曲线得到的相关系数以及对 UMI 计数的统计与原文结果相同；氧化磷酸化过程的 AUC 值直接使用了氧化磷酸化水平分析得到的结果，如前文所述，相对大小和原文一致。




图 20 随机森林预测结果，还统计了其他有关数据。

(A) 复现结果。

(B) 原文结果。

为了进一步确定模型预测的可靠性，可视化预测结果并从模型中提取出权重信息及其对应的基因，如图 21 所示。复现得到的模型的预测能力略差于原文结果，推测可能是由于部分模型参数设置与原文不一致。从复现模型中提取得到的权重较大的基因与原文的结果基本相同，说明复现结果是有效的。这些基因的表达模式如图 22 所示。可以观察到这些基因的确在时间上呈现出了特定的表达模式，其表达含量可以在一定程度表征衰老的程度，从而可以作为衰老的分子标记物用于细胞年龄的预测。




图 21 随机森林预测结果可视化

(A) 复现结果。

(B) 原文结果。




图 22 模型中权重较大的基因的表达模式

(A) 复现结果。

(B) 原文结果。

4.2. 挑战与解决方案

4.2.1. Seurat 聚类分析

在复现 Seurat 聚类分析的过程中，遇到的主要挑战是 t-SNE 降维和聚类算法的随机性。由于这些算法的随机性，复现结果中的 t-SNE 降维图与原文存在较大差异，尤其是细胞簇的位置和分布。在 t-SNE 降维过程中，不同的随机种子可能会导致聚类结果有所不同，尤其是细胞簇的位置分布。尽管如此，使用 聚类纯度 指标进行分析后发现，在边缘聚类的纯度较高，聚类效果整体是有效的。此外，通过比较文献中的标记基因和复现结果中的细胞簇标注，能够确认聚类的有效性，并解决了由于随机性带来的聚类位置差异问题。

4.2.2. SCENIC 调控网络分析

在进行 SCENIC 调控网络分析时，遇到的主要问题来自编程环境的配置。最初计划使用 R 语言版本的 SCENIC 包进行分析，但由于在 Linux 系统中安装 SCENIC 包时出现了一些技术问题，最终决定改用 pySCENIC，并与 Scanpy 包结合使用。这一变化虽然解决了技术问题，但也带来了与原文结果在某些图形呈现上的差异，特别是颜色和调色板的匹配问题。为了解决这一问题，选择将数量较少且未被注释的细胞群体归为“unnamed”，并使用灰色显示，使得其他细胞群体能够通过对比色得到更高的可视化效果。

4.2.3. 氧化磷酸化水平分析

在进行 GO 富集分析时，由于该研究发表于 2018 年，而此后 GO 数据库已存在较大变化，因此我们发现差异显著的 GO 注释与原文中的部分结果有所不同。尽管如此，通过使用不同的差异表达分析方法，仍然得到了与原文一致的结论，即氧化磷酸化水平在不同脑区之间存在显著差异。除此之外，在计算 AUCel 值时，由于原文未明确列出氧化磷酸化相关的基因，可能导致在复现过程中遗漏了部分基因，从而使得计算的 AUCel 值相较于原文有所不同。尽管如此，复现结果仍然显示了不同脑区之间氧化磷酸化水平的相对差异，且与原文结果基本一致。

4.2.4. 单细胞年龄预测

在使用随机森林模型进行单细胞年龄预测时，面临的挑战主要来自算法的随机性问题。由于原文中对这一部分方法的描述相对简略，缺少随机种子等关键信息，复现时不

同参数设置可能导致预测结果的差异。因此，复现过程中得到的年龄预测准确性与原文存在一些差异。尽管如此，整体上，复现结果与原文结果的年龄预测准确性保持一致。此外，为了进一步验证模型的可靠性，复现过程中提取了模型的权重信息，并对其进行可视化，发现权重较大的基因与原文一致。这表明，虽然存在算法的随机性问题，复现结果依然有效且与原文研究结果保持高度一致。

5. 结论

根据本研究的分析和复现结果，可以得到以下结论，从而回答 1.2 中提出的科学问题。

5.1. 果蝇大脑转录组特征差异分析

基于果蝇大脑的转录组学数据，通过聚类分析、特定的基因标志物、转录因子调控网络以及调控子等方式，我们成功地鉴别出了大多数已知的细胞类型及其标志基因。同时，还发现某些调控子的表达差异将大脑分为几个不同的脑区。这些脑区之间最显著的差异是氧化磷酸化基因的表达水平，说明在某些细胞中线粒体或代谢活性有着显著差异。此外，由于先前研究发现这些调控子（如 *pros*, *dati*, *mamo*, *Imp* 等）在神经元的发育过程中有着不同的表达阶段，推测这些来自不同脑区的细胞可能在发育过程中被赋予了不同的代谢潜能。对于这些位于不同脑区的细胞的进一步研究可能为神经网络的发展与建成提供新的见解。

5.2. 大脑衰老的整体性或局部性

通过转录组分析，发现在衰老过程中果蝇大脑细胞中的基因表达呈现出整体性的指数下降趋势。然而在此过程中，各细胞亚群的身份得到了很好的维持，并未发现某些特定的细胞亚群对于衰老有显著不同的基因表达变化。在基因层面，关于调控不同生命过程的基因对于衰老呈现出不同的变化趋势，其中以参与氧化磷酸化过程的基因表达下降最为明显，而与核糖体相关的基因表达则在衰老过程中保持稳定。这说明，衰老过程中的基因表达变化既含有基因组层面的全局表达量下降，也包括细胞中的不同基因对衰老过程的不同响应方式。

5.3. 基于衰老分子标志物的年龄预测

由复现结果可知，一些表达水平随年龄变化较大的基因可以作为表征衰老水平的生物标志物，并且有着很好的预测可靠性。如果想根据这些分子标志物开发预测果蝇大脑细胞年龄预测的方法，还需要在更多的果蝇品系中进一步验证以探究这些生物标志物是

否在不同的品系间具有一致性。此外，对年龄的预测依赖于对不同年龄阶段脑细胞的转录组数据的相对差异，如何简化预测流程、提高预测效率和准确性则需要更进一步的研究。

6. 讨论

6.1. 课题的局限性

6.1.1. 分析技术限制

果蝇神经元体积较小且 RNA 含量较低，这可能导致部分细胞类型或亚型的转录组数据捕获不足。尽管研究已经克服了这一部分挑战，但仍可能存在未被检测到的细胞类型或重要调控信息。同时，单细胞测序技术本身存在噪声和技术偏差，如批次效应或捕获效率的差异，也可能影响分析结果的准确性。

6.1.2. 研究范围仅限于果蝇

研究基于果蝇大脑数据，尽管果蝇是一个经典的模式生物，但其大脑结构和功能与哺乳动物（如人类）存在显著差异，因此研究发现的普适性尚需在其他物种中验证。最新研究同样利用了转录组学分析技术，建立了衰老小鼠大脑单细胞转录组图谱，系统解析衰老相关细胞类型及特异性转录组特征。结合最新的研究结果，可能可以产生更加具有普适性的发现。

6.1.3. 功能验证不足

该研究虽然预测了一些转录因子（如 Imp、pros、dati 等）与代谢路径或神经网络构件的关系，但这些调控机制的生物学功能和因果关系尚未通过实验验证，仍停留在假设阶段。

6.2. 展望

6.2.1. 大脑细胞类型的功能精细化研究

本研究揭示了许多新的神经元亚型和细胞状态，未来可以进一步解析这些亚型的具体功能，例如它们在神经网络中的作用、突触连接模式以及参与的行为或认知功能。其次，通过 SCENIC 工具预测的转录因子网络（如 Imp、pros、dati 等）可以进一步研究其如何协调细胞分化、代谢和功能维持，尤其是在不同发育阶段和环境应激下的动态调控。

6.2.2. 衰老相关机制的深入探索

该研究发现胶质细胞的衰老轨迹明显而神经元的命运在衰老中保持稳定，这提示不同细胞类型的衰老机制可能具有特异性。未来可以进一步研究这些细胞特异性机制如何影响大脑功能和健康寿命。同时，鉴于氧化磷酸化基因的显著下降和核糖体基因的稳定性，后续研究可以探索这些基因变化如何影响细胞代谢、能量供给以及神经元的存活和功能。

6.2.3. 跨物种比较与疾病模型

在果蝇以外，或许可以通过在其他物种（如小鼠和人类）中验证发现的调控网络和代谢模式，可以探究这些机制是否具有跨物种的保守性，从而为理解人类大脑健康和疾病（如阿尔茨海默病）提供新线索，发现新的靶点。

6.2.4. 环境因素对衰老的作用

研究中未讨论外部环境（如饮食、温度、压力）对衰老和基因表达的影响，未来可以结合单细胞技术研究环境因素如何调控不同细胞类型的老化进程。同时，衰老是一个个体差异较大的过程，也许可以进一步研究遗传与个体差异在衰老过程中的影响。

致谢

感谢小组同学的辛勤付出以及全体同学一个学期以来的陪伴。

感谢李程老师的悉心指导。

参考文献

- [1] López-Otín, C., Blasco, M.A., Partridge, L., Serrano, M. & Kroemer, G (2013). The hallmarks of aging. *Cell* **153**, 1194–1217.
- [2] The Tabula Muris Consortium, Almanzar, N., Antony, J., Baghel, A.S., Bakerman, I., Bansal, I., Barres, B.A., Beachy, P.A., Berdnik, D., Bilen, B., *et al.* (2020). A single-cell transcriptomic atlas characterizes ageing tissues in the mouse. *Nature* **583**, 590–595.
- [3] Ma, S., Sun, S., Geng, L., Song, M., Wang, W., Ye, Y., Ji, Q., Zou, Z., Wang, S., He, X., *et al.* (2020). Caloric restriction reprograms the single-cell transcriptional landscape of *Rattus norvegicus* aging. *Cell* **180**, 984–1001.
- [4] Wang, S., Zheng, Y., Li, J., Yu, Y., Zhang, W., Song, M., Liu, Z., Min, Z., Hu, H., Jing, Y., *et al.* (2020). Single-cell transcriptomic atlas of primate ovarian aging. *Cell* **180**, 585–600.

[5] Davie, K., Janssens, J., Koldere, D., De Waegeneer, M., Pech, U., Kreft, Ł., Aibar, S., Makhzami, S., Christiaens, V., Bravo González-Blas, C., *et al.* (2018). A single-cell transcriptome atlas of the aging *Drosophila* brain. *Cell* **174**, 982-998.