

HW2 实验报告

策略评估 (policy evaluation)

根据Bellman方程进行迭代：

$$v_{\pi}(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \sum_{s' \in \mathcal{S}, r \in \mathcal{R}} p(s', r | s, a) [r + \gamma v_{\pi}(s')]$$

对于该环境和随机策略， $p(s', r | s, a)$ 恒为1（确定性的环境）， $\pi(a|s)=0.25$ 。

得到的价值函数 v_{π} 为

3.31	8.79	4.43	5.32	1.49
1.52	2.99	2.25	1.91	0.55
0.05	0.74	0.67	0.36	-0.40
-0.97	-0.43	-0.35	-0.58	-1.18
-1.86	-1.34	-1.23	-1.42	-1.97

和答案基本一致。

此外还简单尝试了TD算法，通过与环境多次交互估计 v_{π} ，结果为

3.39	8.80	4.48	5.34	1.51
1.57	3.06	2.33	2.00	0.58
0.11	0.82	0.70	0.39	-0.38
-0.93	-0.41	-0.30	-0.56	-1.18
-1.85	-1.33	-1.18	-1.41	-1.93

结果整体与直接计算得到的结果差不多，但是需要多次迭代。

策略迭代 (policy iteration)

策略评估和策略提升交替进行，最终得到的 v_* 为

21.98	24.42	21.98	19.42	17.48
19.78	21.98	19.78	17.80	16.02
17.80	19.78	17.80	16.02	14.42
16.02	17.80	16.02	14.42	12.98
14.42	16.02	14.42	12.98	11.68

与答案基本一致。