

NeuroAI: 神经科学启发的类脑人工智能方法

——以大脑皮层中的兴奋-抑制机制为例

刘沛雨

摘要

本报告针对当前人工智能尤其是深度学习在数据和效率方面遭遇的瓶颈，重新聚焦于大脑高效、低功耗的信息处理机制，深入探讨了神经科学对人工智能发展的启发性作用。具体而言，报告以大脑皮层中关键的兴奋-抑制 (E-I) 平衡机制为出发点，设计并实现了一种无需依赖传统归一化技术的深度前馈脉冲神经网络 (EI-SNN) 模型。该模型显式地融入了生物学中兴奋性与抑制性神经元的连接模式，并整合了平衡性抑制与分流抑制这两种核心作用机制。同时，本研究还提出了一套基于生物学原理约束的参数初始化策略，以促进模型的有效训练。实验结果表明，在浅层网络结构（如 VGG5 和 VGG11）上，所提出的 EI-SNN 在图像分类任务中的性能可达到与传统脉冲神经网络相当的性能，初步验证了该生物启发机制在实现网络内部归一化功能方面的潜力与生物学解释力，而将此类生物机制有效扩展至更复杂深度网络并维持其性能鲁棒性，是未来值得深入探索的重要研究方向。本研究为发展兼顾生物可解释性与计算高效性的人工智能新方法提供了一个具体的实现范例和有益的思路。

1 引言：人工智能与神经科学

人工智能的早期发展与神经科学的联系十分密切，甚至可以说由神经科学主导。一些最早的学习算法旨在模拟生物学习的计算模型，关注大脑如何学习以及大脑为什么能够学习。然而，由于彼时对于大脑的功能和机制知之甚少，受神经科学启发的学习方法远远谈不上智能——基于联结主义的线性神经网络模型连简单的异或函数都无法学习，这直接导致了神经网络热潮的第一次大衰退 [1]。自此之后，神经科学在人工智能研究中的作用逐渐被削弱，但在深度学习时代，其仍是人工智能研究中一个重要的灵感来源：深度强化学习、卷积神经网络、注意力机制等里程碑式的作品中均可以看到神经科学的影子。

近年来，神经科学理论与技术的迅猛发展为我们理解智能的本质再次提供了契机，众多研究正逐步揭示大脑的内部奥秘。与此同时，数据驱动的大模型等技术在经历了令人瞩目的性能飞跃后，似乎正面临 scaling law 因可训练数据耗竭而难以为继的挑战——性能提升的曲线逐渐

平缓，增速放缓的趋势日益显现。除此之外，模型训练与推理消耗的大量资源与对环境的负面影响也不可忽略。在这样的背景下，大脑低功耗的信息处理机制与强大的学习能力无疑是极具吸引力的，神经科学也有望再次成为人工智能发展的驱动力。

但一个重要的事实是，尽管今天我们对于大脑学习、记忆等多方面的机制已经有了较为深入的了解，仍然没有足够的信息使我们能够在所有层面上完全理解其工作机制。因此短期内神经科学可能仍然只能作为人工智能的灵感来源和驱动力，而不能在细节上指导人工智能方法的构建。得出此结论的另一个原因是当前主流学习算法与生物学习机制的适配性问题：一些方法如基于全局反向传播（backpropagation, BP）的优化理论与生物学习机制（通常被认为是基于局部状态而非全局状态的学习）并不完全契合，但其对于模型的有效训练确至关重要。

综上所述，当前生物启发（bio-inspired）的人工智能方法往往以生物机制为依据进行数学建模，兼顾生物可解释性和可计算性。这类研究一方面应着重关注模型所呈现出的与非生物启发模型不同的生物学特性，另一方面也不可忽视模型的总体性能指标。本报告将以大脑皮层兴奋-抑制（excitation-inhibition, E-I）机制启发的无需归一化模块（如批次归一化, batch normalization, BN[2]）的深度前馈神经网络架构为例，展示生物学启发如何逐步转化为可有效计算和训练的神经网络模型。初步实验结果表明，该模型架构在浅层网络中能达到与带 BN 网络相当的性能，并在更深层的网络中也可支持有效训练。

2 研究目的

以 BN 为代表的各类归一化技术极大地简化了神经网络的有效训练，使其不再高度依赖于大规模的参数搜索，从而显著加速了网络的训练过程。但一直以来，于归一化方法加速训练的内在机制，目前仍无定论：最初研究者认为 BN 通过减少内部协变量偏移（internal covariate shift, ICS）提高了模型各个层输入分布的一致性，从而加速了模型训练 [2]；而另一项工作则认为归一化通过平滑模型的 loss landscape 加速了模型收敛 [3]。除了机制层面的争论，归一化技术与特定生物学机制的联系也值得探讨，有研究表明兴奋-抑制机制具有增益控制（gain control）的作用，也即通过调节神经元输入-输出映射的比例关系来控制其反应强度和敏感度。[4]。从计算层面看，增益控制与神经网络中的归一化操作存在一定的相似性。归一化技术通过调整输入激活函数（神经元）的均值和方差，使得输入到下一层的激活值保持在一个相对稳定的分布范围内，其同样可以看作是对神经元响应强度的动态调整。

因此，本研究从兴奋-抑制的生物学机制出发，在前人工作 [5] 的基础上对兴奋-抑制机制进行建模，旨在通过兴奋性和抑制性神经元之间的相互作用动态调整兴奋性神经元的输入分布，从而为解释归一化的作用机制及其与兴奋-抑制机制的内在关联提供新的见解，同时也为进一步研究抑制性神经元在学习和认知过程中的重要作用奠定了基础。

3 研究背景

3.1 戴尔原则

大多数神经元仅释放一种类型(兴奋性或抑制性)的神经递质,并作用于与其存在突触连接的所有突触后神经元。这一在神经科学研究中被广泛接受的概念被称为戴尔原则 (Dale's principle) 或戴尔定律 (Dale's law)。该原则在大脑皮层的大部分脑区得到了充分的实验支持,且几乎所有关于神经网络计算机机制的理论研究都以此为基础进行假设 [6]。

简而言之,戴尔原则将神经元大致划分为两大类:兴奋性神经元和抑制性神经元。实验数据显示,在大脑皮层中,兴奋性神经元约占有所有神经元的 70-80%,而抑制性神经元的比例则约为 20-30%[7]。目前对兴奋性神经元的研究相对更为全面,已有许多经典的数学模型能不同程度地模拟其动力学特征,包括泄漏整合-发放 (Leaky Integrate-Fire, LIF) 模型和霍奇金-赫胥黎 (Hodgkin-Huxley) 模型等。相比之下,抑制性神经元因其数量较少、异质性强 [7] 等特点,相关研究相对较少。下文将简要介绍抑制性神经元的基本特征及其在调控网络动态中的基本机制与作用。

3.2 抑制性神经元

与典型的兴奋性神经元(锥体神经元, pyramidal neuron)相比,抑制性神经元具有类型多样、异质性强的特点,且大多分布在大脑皮层功能柱特定层内部,因此也被称为中间神经元 (interneuron)。这些中间神经元通常仅与邻近的神经元形成局部连接,而很少参与形成跨层的突触连接。

从形态学角度看,目前已发现的抑制性神经元可被分为十余种,主要包括篮状细胞 (basket cells) 和双极细胞 (bipolar cells) 等 [7]。从动力学角度看,目前已发现的抑制性神经元主要可以被分为快速脉冲发放 (fast-spiking, FS) 神经元和非快速脉冲发放 (non-fast-spiking, non-FS) 神经元。

3.3 抑制性的两种作用机制

抑制性神经元的作用途径可根据作用水平分为两大类:神经元群体(神经回路)水平上的基于兴奋-抑制平衡的平衡性抑制和单个神经元水平上的基于欧姆定律的分流抑制。

平衡性抑制在大脑皮层中广泛存在,指一个神经元群体接收的抑制性输入和兴奋性输入总体上大小相当,且抑制性输入会随着兴奋性输入的变化而动态调整,能够使神经元群体的整体活动水平保持在相对稳定的区间内,同时允许瞬时或局部活动的震荡。

另一类发生在细胞水平上的抑制是分流抑制 (shunting inhibition),抑制性神经元通过释放抑制性神经递质使靶神经元的膜电导 G 增大,从而使得输入靶神经元的兴奋性电流 I_{ext} 的去极

化作用被削弱（欧姆定律： $\Delta u = I_{ext}/G$ ，其中 Δu 为神经元膜电位变化量）[8]。由于这类抑制的作用特点，其常被认为可以除性地（divisive）进行增益控制。分流抑制通常直接作用于靶神经元的轴突、胞体或靠近胞体的区域，因此能够迅速而精确地调节靶神经元的兴奋性，起到门控（gating）的作用。

4 基于兴奋-抑制机制的前馈脉冲神经网络模型

4.1 两类神经元的连接模式

为了构建基于兴奋-抑制机制的神经网络模型，首先需要确定两类神经元之间可能的连接方式。如前文所述，抑制性神经元通常仅与邻近的兴奋性神经元之间形成突触连接，并且这些连接在空间模式上具有高度多样性，包括前馈（feed-forward）连接、反馈（feedback）连接、侧向（lateral）连接以及循环（recurrent）连接等 [9]，考虑到前馈连接与目前主流的神经网络模型结构一致且易于建模，本研究主要关注前馈连接，初步构建简单的基于兴奋-抑制机制的前馈脉冲神经网络（EI-SNN）模型。

4.2 模块结构




图 1: EI-SNN 的全连接层模块结构（以 LIF 神经元作为激活函数），该模块可以简单地扩展到卷积层。蓝色表示与抑制性通路相关的参数及中间计算量，红色表示与兴奋性通路相关的参数及中间计算量。虚线圆圈表示目前的实现中尚未显式加入抑制性中间 LIF 神经元。

一个 EI-SNN 全连接层的内部结构如图1所示，该设计参考自 Cornford 等人的工作 [5]，并在此基础上设计了针对脉冲神经网络的模型初始化方法。在每一层 l 的可学习参数包括 W_{EE}, W_{IE}, W_{EI} 以及 γ, β, α ，其中 $W_{IE}^{[l]}$ 表示第 l 层的兴奋性神经元群体（E）到抑制性神经元群体（I）的权重矩阵（即突触连接）； $I_{IE}^{[l]}$ 表示由第 l 层兴奋性神经元群体（E）输入抑制性神经元群体（I）的（兴奋性）电流。其余参数下标和上标的含义以此类推。为方便讨论，在不引起歧义的情况下，后

续将略去上标。

接下来定义各个参数矩阵的形状。假设输入 $s_E^{[l-1]}$ 的维度为 d ，兴奋性和抑制性神经元的数量分别为 n_e 和 n_i ，那么 W_{EE}, W_{IE}, W_{EI} 的形状分别为 $n_e \times d, n_i \times d, n_e \times n_i$ ， γ, β, α 的形状分别为 $n_e \times 1, n_e \times 1, n_i \times 1$ 。

4.3 计算模型

4.3.1 前向传播

下面给出前向传播过程中每个全连接层的计算流程。首先计算 I_{EE} 和 I_{IE} ：

$$I_{EE} = W_{EE}s_E, I_{IE} = W_{IE}s_E$$

为了保证模型的可训练性，目前尚未显式加入中间抑制性神经元，而是直接使用 I_{IE} 作为抑制性神经元的输出，即 $s_I = I_{IE}$ （由于 $I_{IE} \geq 0$ ，可认为抑制性神经元为 ReLU 神经元）。抑制性通路需要分别计算减性抑制（即 I_{EI} ）和除性的分流抑制（ $I_{shunting}$ ）：

$$I_{EI} = W_{EI}s_I = W_{EI}I_{IE}$$

$$I_{shunting} = W_{EI}(\alpha \cdot I_{IE})$$

其中 $\cdot$ 表示逐元素相乘（ α 用于调节分流抑制的大小，详见下一小节）。完成上述计算后，下游的兴奋性神经元即可整合各部分电流：

$$I_{balanced} = I_{EE} - I_{EI}$$

$$I_{integrated} = \gamma \cdot \frac{I_{balanced}}{I_{shunting}} + \beta$$

最后，下游兴奋性神经元以 $I_{integrated}$ 作为输入电流发放脉冲至下一层，完成该层的一次前向传播。

4.3.2 模型初始化

这一小节将根据前向传播计算过程以及生物学约束，给出模型参数的初始化方法及推导过程。根据前文所述的兴奋-抑制作用机制，EI-SNN 在计算上应当受到如下生物学约束：

1. 权重矩阵的非负约束： $W_{EE}, W_{IE}, W_{EI} \geq 0$
2. 兴奋性和抑制性神经元的比例： $n_e : n_i = 4 : 1$
3. 兴奋-抑制平衡： $I_{EE} \approx I_{EI}$

4. 分流抑制的增益控制作用

下面将介绍如何从这些约束条件出发，推导模型参数的初始化与参数更新方法。

根据已有的突触建模方法，这里选择将以兴奋性神经元作为突触前神经元的突触权重矩阵（即 W_{EE} 和 W_{IE} ）初始化为指数分布：

$$W_{EE}, W_{IE} \stackrel{i.i.d.}{\sim} \text{Exp}(\lambda)$$

由兴奋-抑制平衡约束可得：

$$\forall k = 1, 2, \dots, n_e, \mathbb{E}(I_{EE,k}) = \mathbb{E}(I_{EI,k})$$

其中

$$\begin{aligned} \mathbb{E}(I_{EE,k}) &= \mathbb{E} \left[\sum_{i=1}^d W_{EE,ki} s_{E,i} \right] \\ &\approx d \mathbb{E}(W_{EE,ki}) \mathbb{E}(s_{E,i}) \\ &= \frac{d}{\lambda} \mathbb{E}(s_{E,i}) \\ &\approx \frac{d}{\lambda} \mathbb{E}(s_E) \\ \mathbb{E}(I_{EI,k}) &= \mathbb{E}[(W_{EI} I_{IE})_k] \\ &= \mathbb{E} \left[\sum_{i=1}^{n_i} W_{EI,ki} I_{IE,i} \right] \\ &\approx n_i \mathbb{E}(W_{EI,ki}) \mathbb{E}(I_{IE,i}) \\ &= n_i \mathbb{E}(W_{EI}) \mathbb{E} \left[\sum_{j=1}^d W_{IE,ij} s_{E,j} \right] \\ &\approx n_i \mathbb{E}(W_{EI}) \frac{d}{\lambda} \mathbb{E}(s_{E,j}) \\ &\approx \frac{dn_i}{\lambda} \mathbb{E}(W_{EI}) \mathbb{E}(s_E) \end{aligned}$$

因此 $\mathbb{E}(W_{EI}) \approx \frac{1}{n_i}$ ，这里选择将 W_{EI} 中的所有元素初始化为 $\frac{1}{n_i}$ 以减少训练过程中（数值不稳定性导致的）除法错误所造成的训练崩溃。

下面结合分流抑制的作用特点与前向传播在计算上与归一化的相似性，假设

$$\forall k = 1, 2, \dots, n_e, \mathbb{E}(I_{shunting,k}) = \text{std}(I_{EE,k})$$

可解得

$$\alpha \approx \frac{1}{\mathbb{E}(s_E)} \sqrt{\frac{\mathbb{E}(s_E^2) + \text{Var}(s_E)}{d}}$$

最后，为了确定指数分布的参数 λ ，令

$$\text{std}(I_{EE}) = \text{std}(s_E)$$

可解得

$$\lambda = \frac{1}{\sqrt{d}} \cdot \frac{\text{std}(s_E)}{\sqrt{\mathbb{E}(s_E^2) + \text{Var}(s_E)}}$$

此外，与已有的归一化方法一致，将 γ 初始化为 1， β 初始化为 0。

由于初始化所需的统计量需要通过输入 s_E 的统计量计算，因此在第一次前向传播时计算 s_E 的有关统计量并完成初始化。该初始化方法通过将 W_{EI} 初始化为 $\frac{1}{n_i}$ ，使得 I_{EI} 和 $I_{shunting}$ 中编码了输入 s_E 中所有元素的均值信息，参数 α 则在此基础上对 $I_{shunting}$ 进行缩放以调控 $I_{balanced}$ 的方差，从而实现了在不调用归一化模块的前提下通过增益控制完成类似归一化的功能。图2展示了初始化时各层的 $I_{integrated}$ 的分布，可以看到该初始化方法同样可以起到归一化输入分布的作用，进一步实验表明，该方法在 VGG5 和 VGG11[10] 上同样具有良好的归一化效果。




图 2: EI-SNN 在初始化时每一层 $I_{integrated}$ 的分布，模型架构为 4 层 MLP，MNIST 数据集分类任务

5 实验结果与讨论

	vanilla-SNN	BN-SNN	EI-SNN
VGG5	0.8369	0.8219	0.8520
VGG11	—	0.8636	0.8529
VGG16	—	0.8786	0.7522

表 1: 模型性能对比。vanilla-SNN: 原始的不带 BN 的网络；BN-SNN: 添加了 BN 的网络。— 表示无法有效训练。

表1展示了初步实验结果，简单对比了 vanilla-SNN、BN-SNN 以及 EI-SNN 在 CIFAR-10 数据集图像分类任务上的性能指标。可以看到，EI-SNN 在浅层网络中具有替代 BN 的潜力，展现出生物启发方法在神经网络设计中的可行性。然而，随着网络深度的增加（VGG11 和 VGG16），

EI-SNN 的性能出现了下滑: 在 VGG11 上, EI-SNN 的准确率 (0.8529) 略低于 BN-SNN (0.8636); 而在 VGG16 上, EI-SNN 的准确率 (0.7522) 更是显著低于 BN-SNN (0.8786), 甚至低于其在 VGG5 上的表现。这表明当前 EI-SNN 的归一化机制在处理更深层次的网络时, 其鲁棒性和稳定性有所下降。深层网络中可能存在更复杂的相互作用和信息流, 仅仅通过模拟归一化来设计兴奋-抑制模块可能不足以维持训练的稳定性和有效的梯度传播, 这也暗示了生物体中兴奋-抑制机制可能存在比归一化更复杂的动力学特征。如何将这种生物学归一化机制有效扩展到更深、更复杂的网络结构中, 以实现与现有归一化技术相当甚至超越这些技术的训练稳定性和性能, 将是后续研究的一个重要方向。

参考文献

- [1] Goodfellow et al. *Deep Learning*. MIT Press, 2016.
- [2] Ioffe et al. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning*, 2015.
- [3] Santurkar et al. How does batch normalization help optimization? In *Advances in Neural Information Processing Systems*, 2018.
- [4] Isaacson JS et al. How inhibition shapes cortical activity. *Neuron*, 2011.
- [5] Cornford et al. Learning to live with dale’s principle: ANNs with separate excitatory and inhibitory units. In *International Conference on Learning Representations*, 2021.
- [6] Barranca VJ et al. Functional implications of dale’s law in balanced neuronal network dynamics and decision making. *Front. Neurosci.*, 2022.
- [7] H. Markram et al. Interneurons of the neocortical inhibitory system. *Nat. Rev. Neurosci.*, 2004.
- [8] Wulfram Gerstner et al. *Neuronal Dynamics: From single neurons to networks and models of cognition*. Cambridge University Press, 2014.
- [9] René Wilbers et al. Structural and functional specializations of human fast-spiking neurons support fast cortical signaling. *Sci. Adv.*, 2023.
- [10] K. Simonyan et al. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations*, 2015.