

基于脉冲时间编码的 ANN-SNN 一致映射方法

刘沛雨

摘要

脉冲神经网络 (SNN) 因其事件驱动和高能效的特性被视为下一代人工智能的关键技术,但其训练一直面临挑战。现有的主流训练方法,如基于代理梯度的直接训练和 ANN-SNN 转换,分别在性能可扩展性与计算效率上存在局限。为融合二者优势,本报告复现并分析了 Stanojevic 等人于 2024 年提出的最新研究,该研究通过建立一种创新的 ReLU 激活值与首次脉冲时间 (TTFS) 编码之间的一致性映射 (identity mapping),解决了 SNN 在反向传播中梯度缩放不一致的核心问题。此方法不仅在前向传播中精确模拟了 ReLU-ANN 的计算,更在反向传播中实现了梯度的等价传递。复现实验在 MNIST 和 FashionMNIST 数据集上验证了该方法能够使 TTFS-SNN 达到与对应的 ReLU-ANN 几乎完全一致的性能,并且在整个训练过程中两者权重保持着接近 1 的余弦相似度,证明了其在理论与实践上的计算等价性。这项工作作为构建兼具深度学习高性能与脉冲计算高效率的神经网络提供了坚实的理论基础与全新的实现范式。相关的复现代码已开源: <https://github.com/vw0v0wv/TTFS-PyTorch>。

1 引言

作为下一代神经网络的有力竞争者,脉冲神经网络 (spiking neural networks, SNNs) 正吸引着学术界和工业界的广泛关注。SNN 使用与生物神经元具有相似动力学特征的神经元作为激活函数,以二值化的脉冲在网络中的各个层之间编码并传递信息。典型的脉冲神经元包括整合-发放 (integrate-and-fire, IF) 神经元和泄漏整合-发放 (leaky integrate-and-fire) 神经元等。与人工神经网络 (artificial neural networks, ANNs) 中的激活函数 (如 ReLU 和 sigmoid 等) 相比,脉冲神经元最大的特点在于其自身具有内部状态 (如膜电位),因此在理论上 SNN 不仅具有与 ANN 同等的表达能力 [1],同时还具有高度的时间动态性和对时序信息的处理能力。本部分将聚焦于 SNN 的两个核心方面——脉冲编码机制与主流的监督学习算法,借此介绍其相关理论基础。

1.1 脉冲编码机制

在生物大脑皮层和 SNN 中，信息主要通过脉冲序列（spike trains）来表示和传递，而非依赖单个脉冲的具体波形。信息编码的策略通常可分为两大核心类别：频率编码（rate coding）和时间编码（temporal coding）[2]。频率编码假设信息包含于神经元在特定时间窗口内的平均发放频率之中，神经元发放的脉冲的频率越高，代表其编码的信号强度越大或越重要。与频率编码相比，时间编码认为脉冲的精确发放时刻或脉冲之间的相对时间间隔本身就携带了关键信息。由于时间编码在连续的时域编码信息，其能够以更少的脉冲表示和传递更丰富的信息，具体形式包括首次脉冲时间（time-to-first-spike, TTFS）编码、脉冲相位（phase-of-firing）编码和脉冲排序（rank-order）编码等，其中 TTFS 编码是本报告关注并使用的主要方法。

1.2 SNN 的主流有监督训练算法

目前主流的 SNN 有监督训练算法可分为两大类。第一类是直接训练 SNN。由于神经元发放脉冲是一个离散、不可微的事件（all-or-none），这给标准的基于梯度的反向传播算法带来了巨大挑战。为了解决这一问题，现有研究往往在反向传播时采用代理梯度（surrogate gradient）[3] 的方法。其核心思想是在反向传播过程中，用一个平滑可微的函数（代理梯度）来近似脉冲函数的真实梯度，使得梯度能够顺利地在网络中反向传播，从而实现端到端的模型训练。

第二类是基于 ANN 到 SNN 的转换。该方法首先在 ANN 框架下训练得到一个高性能的模型，之后再通过一系列转换技术，将训练好的网络权重和结构映射到一个与之等效的 SNN 中。其基本原理是将神经元的连续激活值（如 ReLU 激活函数的输出）对应为脉冲神经元的平均发放频率（频率编码）或脉冲发放时间（时间编码）。通过这种方式，目前转换后的 SNN 已经能够以极低的时延和能耗达到接近原 ANN 的性能 [4]。

2 研究动机

随着研究的不断深入，前文所述的两大主流训练方法（直接训练与 ANN-SNN 转换）正逐渐展现出互相融合的趋势，催生出新的研究思路。直接训练虽然能充分发挥 SNN 的时序动态特性，但其性能和网络深度仍受代理梯度等技术限制；而 ANN-SNN 转换虽能构建高性能的深度网络，却往往继承了 ANN 基于频率编码的假设，导致较高的脉冲发放率和能耗，未能完全利用 SNN 在时间编码上的潜力。

为了打破这两种方法的壁垒，研究者们开始探索如何将 ANN 成功的设计原则（如 ReLU 激活函数）与 SNN 的脉冲动力学更高效地结合。一个核心的挑战在于：能否设计一种新型的脉冲神经元模型或激活机制，使其在行为上能精确地、高效地模拟传统 ANN 中的关键计算单元，同时又能保持 SNN 稀疏和事件驱动等优势。

基于上述分析，本报告主要分析和复现了 Stanojevi 等人于 2024 年发表在 Nature Communications 上的工作 [5]。该研究正是对上述问题的一个创新性回应，作者并未直接采用传统的 ANN-to-SNN 转换，而是在前人的基础上进一步设计 ReLU 激活函数输出与脉冲神经元的脉冲发放时间之间的精确映射关系 [5]。这种设计巧妙地融合了两类方法的优点：既可以用于直接训练 SNN，在 SNN 框架内进行前向传播和梯度计算，又借鉴了 ANN-SNN 转换的核心思想，即在计算上模仿 ReLU 激活函数。该方法使 SNN 达到了与 ANN 同等的性能，并且显著提升了网络的计算效率和稀疏性，为构建兼具高精度与高效率的深度 SNN 提供了新的范式。

3 方法

本部分将主要介绍原研究的核心内容和主要发现。

3.1 两阶段 IF 神经元




图 1: 两阶段 IF 神经元示意图，修改自 [5]

该研究使用的神经元模型如图1所示，每个神经元使用 TTFS 编码，具体而言，数值 x 被编码为 $\frac{t_{\max} - x}{\tau_c}$ ($t_{\max}$ 的定义见下)。神经元处理信息的过程可被分为整合 (integrating) 和发放 (firing) 两个互不重叠的阶段。第 n 层神经元发放脉冲的时间窗口为 $[t_{\min}^{(n)}, t_{\max}^{(n)}]$ ，而在此之前第 n 层神经元在时间 $[t_{\min}^{(n-1)}, t_{\max}^{(n-1)}]$ 内整合来自第 $n-1$ 层神经元的脉冲。

第 n 层神经元 i 的动力学方程为

$$\tau_c \frac{dV_i^{(n)}}{dt} = \begin{cases} A_i^{(n)} + \sum_j W_{ij}^{(n)} H(t - t_j^{(n-1)}), & t < t_{\min}^{(n)} \\ B_i^{(n)}, & t_{\min}^{(n)} \leq t < t_{\max}^{(n)} \end{cases} \quad (1)$$

其中 τ_c 为时间常数, 本研究中设为 1, $V_i^{(n)}$ 表示第 n 层的神经元 i 的膜电位, $A_i^{(n)}, B_i^{(n)}$ 为标量 (本研究中 $A_i^{(n)} = 0$), $W_{ij}^{(n)}$ 表示第 $n-1$ 层神经元 j 到第 n 层神经元 i 的突触权重, H 为 Heaviside 函数, $t_j^{(n-1)}$ 为第 $n-1$ 层神经元 j 发放脉冲的时间 (如果不发放脉冲则为 0)。

除此之外, 神经元还受到如下约束 (以第 n 层神经元为例) (1) $t_{\max}^{(n-1)} = t_{\min}^{(n)}$ 。即第 $n-1$ 层神经元发放阶段结束后第 n 层神经元才开始发放脉冲, 而在此之前第 n 层神经元整合来自第 $n-1$ 层神经元的脉冲。(2) 神经元仅可以在发放阶段发放至多一个脉冲。该约束可通过动态阈值机制实现:

$$\vartheta_i^{(n)} := \tilde{\vartheta}_i^{(n)} - D_i^{(n)} \quad (2)$$

其中 $\vartheta_i^{(n)}$ 为本次计算中神经元 i 的阈值, 其由一个固定的初始阈值 $\tilde{\vartheta}_i^{(n)}$ 和一个可学习参数 $D_i^{(n)}$ 作差得到。

3.2 ReLU 激活值与脉冲发放时间的一致映射

在完成对神经元模型的定义后, 即可根据该模型建立前向传播过程中 ReLU 神经元和脉冲神经元的一致映射 (identity mapping), 该方法来自 Stanojevi 等人的另一篇工作 [6]。

由式(1)和(2)以及 $A_i^{(n)} = 0$ 可推出第 n 层神经元 i 在约束条件下发放脉冲的时间 $t_i^{(n)}$ (如果神经元 i 发放脉冲), 将结果整理可得:

$$\frac{t_{\max}^{(n)} - t_i^{(n)}}{\tau_c} = \sum_j \left(\frac{W_{ij}^{(n)}}{B_i^{(n)}} \cdot \frac{t_{\max}^{(n-1)} - t_j^{(n-1)}}{\tau_c} \right) + \frac{t_{\max}^{(n-1)} - t_{\min}^{(n-1)}}{\tau_c} - \frac{\vartheta_i^{(n)}}{B_i^{(n)}} \quad (3)$$

从式(3)中可以注意到: 当且仅当一个 ANN 网络对应的神经元 i 与上游神经元 j 的突触权重及其偏置 β_i 满足

$$\begin{aligned} (1) \quad w_{ij} &= \frac{W_{ij}^{(n)}}{B_i^{(n)}} \\ (2) \quad \beta_i &= \frac{t_{\max}^{(n-1)} - t_{\min}^{(n-1)}}{\tau_c} - \frac{\vartheta_i^{(n)}}{B_i^{(n)}} \end{aligned}$$

时, 该神经元输出非负激活值等价于 SNN 中对应的 TTFS 脉冲神经元在约束条件下发放脉冲。因此, 在使用 TTFS 编码的情况下, 我们可以将一个 ReLU-ANN 转换为在前向传播的计算上完全等价的 TTFS-SNN。

3.3 反向传播过程中的一致映射

[6] 中已经成功建立了在前向传播过程中的一致映射, 但得到的 SNN 在性能以及训练过程中的收敛速度上仍与对应的 ANN 存在差距。由于 SNN 在前向传播时已经与对应的 ANN 完全等价, 问题可能存在于反向传播过程中对梯度的计算上。

对于 TTFS 编码的 SNN，突触权重 $W^{(n)}$ 的梯度为

$$\frac{d\mathcal{L}}{dW^{(n)}} = \frac{d\mathcal{L}}{dV^{(N)}} \frac{dV^{(N)}}{dt^{(N-1)}} \frac{dt^{(N-1)}}{dt^{(N-2)}} \cdots \frac{dt^{(n+1)}}{dt^{(n)}} \frac{dt^{(n)}}{dW^{(n)}} \quad (4)$$

其中 $\mathcal{L}$ 为计算得到的损失， N 为模型的层数（第 N 层为输出层）。根据式(4)可以计算雅可比矩阵

$$\frac{dt^{(n)}}{dt^{(n-1)}} = M^{(n-1)} \cdot \frac{1}{B^{(n)}} \cdot W^{(n)} \quad (5)$$

其中 $M^{(n)}$ 为 0-1 对角矩阵，作为对梯度的门控（第 n 层神经元 i 发放脉冲则 $M_{ii}^{(n)} = 1$ ，否则为 $M_{ii}^{(n)} = 0$ ）， $B^{(n)}$ 同样为对角矩阵， $B_{ii}^{(n)} = B_i^{(n)}$ 。

从式(5)中即可发现问题。在先前的研究中，不同的神经元 i 往往具有不同的 $B_i^{(n)}$ ，这导致在反向传播的过程中不同神经元突触权重的梯度被做了不同程度的缩放（scale），导致不同神经元权重更新幅度不一致。而在 ReLU-ANN 中，ReLU 神经元在输入大于 0 时反向传播梯度恒等于 1，因此不存在 SNN 中的问题。根据式(5)可知：简单地令第 n 层所有神经元 i 的 $B_i^{(n)}$ 均等于 1 即可使 TTFS-SNN 和对应的 ReLU-ANN 在反向传播过程中也完全等价，从而使得两个网络在整个训练过程中均等价。

4 实验结果

4.1 复现结果

Model	Arch.	Test acc. [%] (from paper)	Test acc. [%] (reproduced)
ReLU	FC2	98.30	98.38
TTFS	FC2	98.30	98.40
ReLU	FC16	98.43 $\pm$ 0.07	98.14
TTFS	FC16	98.43 $\pm$ 0.07	98.16
ReLU	VGG16	99.57 $\pm$ 0.01	99.59
TTFS	VGG16	99.58 $\pm$ 0.01	99.50
MNIST			
Model	Arch.	Test acc. [%] (from paper)	Test acc. [%] (reproduced)
ReLU	FC2	90.14	90.22
TTFS	FC2	90.14	90.31
ReLU	LeNet5	90.91 $\pm$ 0.17	90.73
TTFS	LeNet5	90.94 $\pm$ 0.25	90.80
FashionMNIST			

图 2: 不同架构的 TTFS-SNN 在 MNIST 和 FashionMNIST 上的性能

图2展示了该研究设计的 TTFS-SNN 模型在性能上完全可达到与 ReLU-ANN 几乎一致的性能。由于实验较多，超参数等实验细节不在此赘述，详情请参见 <https://github.com/vw0v0wv/TTFS-PyTorch>，其中文件夹 configs/examples 中记录了所有复现实验的配置文件，可直接运行以复现结果。

为了确认训练过程中 TTFS-SNN 的确可以和对应的 ReLU-ANN 维持等价关系，我们计算了每个 epoch 开始时 ReLU-ANN 和对应的 TTFS-SNN 中所有对应权重的余弦相似度的平均值，结果如图3所示。在整个训练过程均余弦相似度几乎持续保持在 1 附近，可见新方法 TTFS-SNN 和 ReLU-ANN 的训练完全一致。




图 3: TTFS-SNN 和 ReLU-ANN 在训练过程中可维持等价关系

4.2 局限与不足

本次复现总体较为成功，通过独立编写代码复现了原始论文 [5] 中的核心结果，并通过可视化证明了复现结果的正确性。目前仍有一些功能尚未实现，如模型在噪声等干扰条件下的鲁棒性测试以及对批次归一化 (batch normalization, BN) 的支持。前者由于时间关系尚未复现，后者由于原论文给出的代码中将 BN 融合在权重之中，实现存在一定困难。

5 讨论

本报告成功复现并验证了一种在 ReLU-ANN 与 TTFS-SNN 之间建立计算等价性的先进方法。该研究的核心贡献在于，通过设计两阶段 IF 神经元模型，特别是统一关键参数 $B_i^{(n)}$ ，该方法不仅实现了前向传播的精确对齐，更解决了 SNN 在反向传播中因神经元异质性导致的梯度缩放不一致问题。实验结果表明，依此构建的 TTFS-SNN 在整个训练迭代过程中，其权重变化轨迹与对应的 ReLU-ANN 几乎完全重合，从而获得了同等的模型性能。

如前文所述，本次复现工作尚存改进空间。未来的研究方向应首先致力于实现对 BN 的完全兼容。BN 是训练现代深度网络的关键技术，解决其在 SNN 等价模型中的实现难题，是将此方法推广至深层模型以及 ImageNet 等大规模数据集的必要前提。其次，系统性地评估模型在噪声注入、参数量化等条件下的鲁棒性也至关重要。

参考文献

- [1] Wolfgang Maass. Networks of spiking neurons: The third generation of neural network models. *Neural Networks*, 1997.

- [2] Wulfram Gerstner et al. *Neuronal Dynamics: From single neurons to networks and models of cognition*. Cambridge University Press, 2014.
- [3] Neftci et al. Surrogate gradient learning in spiking neural networks: Bringing the power of gradient-based optimization to spiking neural networks. *IEEE Signal Processing Magazine*, 2019.
- [4] Tong Bu et al. Optimal ann-snn conversion for high-accuracy and ultra-low-latency spiking neural networks. In *International Conference on Learning Representations*, 2023.
- [5] Stanojevic et al. High-performance deep spiking neural networks with 0.3 spikes per neuron. *Nature Communications*, 2024.
- [6] Stanojevic et al. An exact mapping from relu networks to spiking neural networks. *Neural Networks*, 2023.